

VIỆN HÀN LÂM KHOA HỌC VÀ CÔNG NGHỆ VIỆT NAM  
HỌC VIỆN KHOA HỌC VÀ CÔNG NGHỆ



**BÁO CÁO TIỂU LUẬN KẾT THÚC HỌC  
PHẦN THẠC SĨ  
TRUYỀN THÔNG ĐA PHƯƠNG TIỆN**

**ĐỀ TÀI  
EDGE-CLOUD COMPUTING CHO TRUYỀN  
THÔNG ĐA PHƯƠNG TIỆN VÀ PHÂN TÍCH NGỮ  
NGHĨA DỮ LIỆU HÌNH ẢNH LỚN**

|                           |                      |
|---------------------------|----------------------|
| <b>Học viên thực hiện</b> | : Trần Đại Dương     |
| <b>Mã học viên</b>        | : 25810009           |
| <b>Lớp</b>                | : ITT2025            |
| <b>Giảng viên</b>         | : TS. Nguyễn Như Sơn |

*Hà Nội, Tháng 5 năm 2026*

# PHIẾU CHẤM ĐIỂM

**Học viên thực hiện:**

| Họ và tên      | Chữ ký | Ghi chú |
|----------------|--------|---------|
| Trần Đại Dương |        |         |

**Giảng viên chấm:**

| Họ và tên          | Điểm | Chữ ký |
|--------------------|------|--------|
| Giảng viên chấm 1: |      |        |
| Giảng viên chấm 2: |      |        |

## LỜI CẢM ƠN

Lời đầu tiên, em xin gửi lời cảm ơn chân thành đến thầy giáo **TS. Nguyễn Như Sơn** đã hướng dẫn, định hướng và hỗ trợ em trong quá trình học tập học phần **Truyền thông đa phương tiện**. Những kiến thức về xử lý dữ liệu đa phương tiện, truyền tải nội dung, hệ thống phân tán và các xu hướng ứng dụng trí tuệ nhân tạo đã giúp em có cơ sở để thực hiện bài tiểu luận với đề tài *“Edge-cloud computing cho truyền thông đa phương tiện và phân tích ngữ nghĩa dữ liệu hình ảnh lớn”*.

Em cũng xin cảm ơn Học viện Khoa học và Công nghệ đã tạo điều kiện học tập, nghiên cứu và tiếp cận các kiến thức mới trong lĩnh vực công nghệ thông tin. Trong quá trình thực hiện, mặc dù đã cố gắng tìm hiểu và hệ thống hóa nội dung, bài tiểu luận khó tránh khỏi thiếu sót. Em kính mong nhận được các ý kiến góp ý của thầy để bài làm được hoàn thiện hơn.

Em xin chân thành cảm ơn!

Hà Nội, ngày 16 tháng 5 năm 2026

**HỌC VIÊN THỰC HIỆN**

**Trần Đại Dương**

## TÓM TẮT

Sự gia tăng nhanh chóng của dữ liệu hình ảnh và video trong các hệ thống truyền thông đa phương tiện đặt ra yêu cầu xử lý lớn về băng thông, độ trễ, năng lực tính toán và khả năng khai thác ngữ nghĩa. Mô hình xử lý tập trung trên cloud có ưu điểm về tài nguyên tính toán nhưng làm tăng chi phí truyền tải và độ trễ, đặc biệt khi dữ liệu phát sinh liên tục từ camera, thiết bị di động hoặc hệ thống giám sát. Ngược lại, xử lý hoàn toàn tại edge giúp giảm độ trễ và bảo vệ dữ liệu cục bộ, nhưng bị hạn chế bởi tài nguyên phần cứng. Vì vậy, mô hình edge–cloud computing được xem là hướng tiếp cận phù hợp để kết hợp ưu điểm của cả hai phía.

Bài tiểu luận này trình bày tổng quan về edge–cloud computing trong truyền thông đa phương tiện, phân tích bài toán xử lý ngữ nghĩa dữ liệu hình ảnh lớn, đề xuất kiến trúc hệ thống phối hợp giữa edge và cloud, đồng thời xây dựng phương pháp đánh giá dựa trên các chỉ số: độ trễ, băng thông, độ chính xác, tài nguyên tính toán và khả năng mở rộng. Nội dung bài tập trung vào kịch bản phân tích ảnh/video bằng mô hình học sâu, trong đó edge thực hiện tiền xử lý và suy luận nhanh bằng mô hình nhẹ; cloud xử lý các trường hợp phức tạp bằng mô hình mạnh hơn và lưu trữ siêu dữ liệu ngữ nghĩa phục vụ tìm kiếm, thống kê và ra quyết định.

## Mục lục

|                                                                       |           |
|-----------------------------------------------------------------------|-----------|
| TÓM TẮT .....                                                         | 4         |
| DANH MỤC CÁC KÝ HIỆU, TỪ VIẾT TẮT .....                               | 9         |
| DANH MỤC HÌNH ẢNH .....                                               | 11        |
| DANH MỤC BẢNG .....                                                   | 12        |
| LỜI MỞ ĐẦU .....                                                      | 13        |
| <b>CHƯƠNG 1: TỔNG QUAN VÀ XÁC ĐỊNH BÀI TOÁN NGHIÊN CỨU</b>            | <b>14</b> |
| 1.1 Bối cảnh hình thành đề tài .....                                  | 14        |
| 1.2 Phát biểu bài toán nghiên cứu .....                               | 14        |
| 1.3 Đối tượng, phạm vi và giả định nghiên cứu .....                   | 15        |
| 1.3.1 Đối tượng nghiên cứu .....                                      | 15        |
| 1.3.2 Phạm vi nghiên cứu .....                                        | 15        |
| 1.3.3 Giả định nghiên cứu .....                                       | 16        |
| 1.4 Mục tiêu nghiên cứu .....                                         | 17        |
| 1.4.1 Mục tiêu tổng quát .....                                        | 17        |
| 1.4.2 Mục tiêu cụ thể .....                                           | 17        |
| 1.5 Câu hỏi nghiên cứu và giả thuyết .....                            | 18        |
| 1.6 Đóng góp dự kiến của đề tài .....                                 | 19        |
| 1.7 Kết luận chương 1 .....                                           | 19        |
| <b>CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN....</b>          | <b>20</b> |
| 2.1 Cloud computing trong xử lý đa phương tiện .....                  | 20        |
| 2.2 Edge computing và fog computing .....                             | 20        |
| 2.3 Collaborative inference giữa edge và cloud .....                  | 21        |
| 2.4 Phân tích ngữ nghĩa dữ liệu hình ảnh .....                        | 21        |
| 2.5 Các mô hình triển khai: cloud-only, edge-only và edge-cloud ..... | 22        |
| 2.6 Tổng quan nghiên cứu liên quan .....                              | 23        |

|     |                         |    |
|-----|-------------------------|----|
| 2.7 | Kết luận chương 2 ..... | 24 |
|-----|-------------------------|----|

### **CHƯƠNG 3: MÔ HÌNH NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG**

|       |                                          |           |
|-------|------------------------------------------|-----------|
|       | <b>ĐỀ XUẤT .....</b>                     | <b>25</b> |
| 3.1   | Quan điểm thiết kế mô hình .....         | 25        |
| 3.2   | Yêu cầu chức năng và phi chức năng ..... | 25        |
| 3.2.1 | Yêu cầu chức năng .....                  | 25        |
| 3.2.2 | Yêu cầu phi chức năng .....              | 26        |
| 3.3   | Kiến trúc tổng thể .....                 | 26        |
| 3.4   | Luồng xử lý dữ liệu .....                | 27        |
| 3.5   | Mô hình dữ liệu ngữ nghĩa .....          | 28        |
| 3.6   | Cơ chế offloading đề xuất .....          | 29        |
| 3.7   | Thuật toán xử lý đề xuất .....           | 30        |
| 3.8   | Kết luận chương 3 .....                  | 31        |

### **CHƯƠNG 4: THIẾT KẾ THỰC NGHIỆM VÀ PHƯƠNG PHÁP ĐÁNH**

|       |                                              |           |
|-------|----------------------------------------------|-----------|
|       | <b>GIÁ.....</b>                              | <b>32</b> |
| 4.1   | Mục tiêu thực nghiệm .....                   | 32        |
| 4.2   | Môi trường thực nghiệm đề xuất .....         | 32        |
| 4.3   | Dữ liệu thực nghiệm .....                    | 33        |
| 4.4   | Các mô hình đối chứng .....                  | 34        |
| 4.5   | Kịch bản thực nghiệm .....                   | 34        |
| 4.5.1 | Kịch bản 1: So sánh độ trễ .....             | 34        |
| 4.5.2 | Kịch bản 2: So sánh băng thông .....         | 35        |
| 4.5.3 | Kịch bản 3: So sánh độ chính xác .....       | 35        |
| 4.5.4 | Kịch bản 4: Thay đổi ngưỡng confidence ..... | 35        |
| 4.5.5 | Kịch bản 5: Giả lập mạng yếu .....           | 36        |
| 4.6   | Bộ chỉ số đánh giá .....                     | 36        |
| 4.7   | Thiết kế dashboard và log thực nghiệm .....  | 37        |
| 4.8   | Quy trình thực nghiệm tổng quát .....        | 37        |

|     |                         |    |
|-----|-------------------------|----|
| 4.9 | Kết luận chương 4 ..... | 37 |
|-----|-------------------------|----|

## **CHƯƠNG 5: KHUNG ĐÁNH GIÁ, PHÂN TÍCH ĐỊNH TÍNH VÀ KHẢ**

### **NĂNG ỨNG DỤNG MÔ HÌNH..... 39**

|       |                                                |    |
|-------|------------------------------------------------|----|
| 5.1   | Lý do lựa chọn đánh giá định tính .....        | 39 |
| 5.2   | Khung so sánh các mô hình triển khai .....     | 39 |
| 5.3   | Phân tích định tính theo từng tiêu chí .....   | 41 |
| 5.3.1 | Độ trễ xử lý .....                             | 41 |
| 5.3.2 | Băng thông truyền tải .....                    | 41 |
| 5.3.3 | Độ chính xác phân tích .....                   | 42 |
| 5.3.4 | Tài nguyên tính toán .....                     | 42 |
| 5.3.5 | Khả năng mở rộng .....                         | 42 |
| 5.4   | Khung kết quả nếu triển khai thực nghiệm ..... | 43 |
| 5.5   | Giá trị nghiên cứu của mô hình đề xuất .....   | 43 |
| 5.6   | Khả năng ứng dụng thực tế .....                | 44 |
| 5.7   | Hạn chế của nghiên cứu .....                   | 44 |
| 5.8   | Kết luận chương 5 .....                        | 44 |

## **CHƯƠNG 6: KHẢ NĂNG TRIỂN KHAI VÀ ỨNG DỤNG THỰC TẾ .. 46**

|     |                                                    |    |
|-----|----------------------------------------------------|----|
| 6.1 | Ứng dụng trong giám sát video thông minh .....     | 46 |
| 6.2 | Ứng dụng trong giao thông thông minh .....         | 46 |
| 6.3 | Ứng dụng trong kho ảnh số và truyền thông số ..... | 46 |
| 6.4 | Ứng dụng trong công nghiệp và kho bãi .....        | 47 |
| 6.5 | Kiến trúc ứng dụng mẫu .....                       | 47 |
| 6.6 | Lộ trình triển khai sản phẩm thử nghiệm .....      | 47 |
| 6.7 | Kết luận chương 6 .....                            | 48 |

## **CHƯƠNG 7: THÁCH THỨC, BẢO MẬT VÀ HƯỚNG PHÁT TRIỂN.. 49**

|     |                                                     |    |
|-----|-----------------------------------------------------|----|
| 7.1 | Thách thức về cân bằng độ trễ và độ chính xác ..... | 49 |
| 7.2 | Thách thức về quản lý mô hình .....                 | 49 |

|                                 |                                      |           |
|---------------------------------|--------------------------------------|-----------|
| 7.3                             | Bảo mật và riêng tư dữ liệu .....    | 49        |
| 7.4                             | Hướng phát triển nghiên cứu .....    | 50        |
| 7.5                             | Kết luận chương 7 .....              | 50        |
| <b>CHƯƠNG 8: KẾT LUẬN .....</b> |                                      | <b>51</b> |
| 8.1                             | Kết quả đạt được .....               | 51        |
| 8.2                             | Ý nghĩa nghiên cứu và ứng dụng ..... | 51        |
| 8.3                             | Hạn chế .....                        | 51        |
| 8.4                             | Hướng nghiên cứu tiếp theo .....     | 52        |
| <b>TÀI LIỆU THAM KHẢO .....</b> |                                      | <b>53</b> |



## DANH MỤC CÁC KÝ HIỆU, TỪ VIẾT TẮT

| Viết tắt | Ý nghĩa                                                                                  |
|----------|------------------------------------------------------------------------------------------|
| AI       | Artificial Intelligence – Trí tuệ nhân tạo.                                              |
| API      | Application Programming Interface – Giao diện lập trình ứng dụng.                        |
| CNN      | Convolutional Neural Network – Mạng nơ-ron tích chập.                                    |
| CPU      | Central Processing Unit – Bộ xử lý trung tâm.                                            |
| DNN      | Deep Neural Network – Mạng nơ-ron sâu.                                                   |
| Edge     | Lớp xử lý gần nguồn phát sinh dữ liệu, ví dụ camera gateway, thiết bị IoT, máy chủ biên. |
| GPU      | Graphics Processing Unit – Bộ xử lý đồ họa, thường dùng tăng tốc học sâu.                |
| IoT      | Internet of Things – Internet vạn vật.                                                   |
| mAP      | mean Average Precision – Độ chính xác trung bình dùng trong phát hiện đối tượng.         |
| QoS      | Quality of Service – Chất lượng dịch vụ.                                                 |
| RTSP     | Real Time Streaming Protocol – Giao thức truyền video thời gian thực.                    |
| SLA      | Service Level Agreement – Thỏa thuận mức dịch vụ.                                        |

| <b>Viết tắt</b> | <b>Ý nghĩa</b>                                                        |
|-----------------|-----------------------------------------------------------------------|
| YOLO            | You Only Look Once – Nhóm mô hình phát hiện đối tượng thời gian thực. |

## DANH MỤC HÌNH ẢNH

|     |                                                                                 |    |
|-----|---------------------------------------------------------------------------------|----|
| 1.1 | Mô tả bài toán nghiên cứu của đề tài .....                                      | 15 |
| 3.1 | Kiến trúc edge–cloud đề xuất cho phân tích ngữ nghĩa dữ liệu hình ảnh lớn ..... | 27 |
| 3.2 | Quy trình xử lý và quyết định offloading .....                                  | 28 |
| 4.1 | Quy trình thực nghiệm đề xuất.....                                              | 37 |
| 6.1 | Kiến trúc ứng dụng mẫu cho hệ thống phân tích ảnh/video edge–cloud              | 47 |

## DANH MỤC CÁC BẢNG

|     |                                                            |    |
|-----|------------------------------------------------------------|----|
| 1.1 | Câu hỏi nghiên cứu của đề tài .....                        | 18 |
| 2.1 | So sánh ba mô hình triển khai xử lý ảnh/video .....        | 23 |
| 3.1 | Quy tắc offloading đề xuất .....                           | 30 |
| 4.1 | Môi trường thực nghiệm đề xuất .....                       | 33 |
| 4.2 | Nhóm chỉ số đánh giá hiệu năng hệ thống .....              | 36 |
| 4.3 | Nhóm chỉ số đánh giá chất lượng phân tích và chi phí ..... | 36 |
| 5.1 | Khung so sánh định tính giữa các mô hình triển khai .....  | 40 |
| 5.2 | Khuôn mẫu ghi nhận kết quả thực nghiệm .....               | 43 |

## LỜI MỞ ĐẦU

Trong bối cảnh chuyển đổi số, dữ liệu đa phương tiện, đặc biệt là hình ảnh và video, được tạo ra với tốc độ ngày càng lớn từ camera giám sát, thiết bị di động, cảm biến đô thị thông minh, nền tảng mạng xã hội, hệ thống giao thông và các ứng dụng công nghiệp. Khác với dữ liệu văn bản truyền thống, dữ liệu hình ảnh lớn có dung lượng cao, cấu trúc phức tạp và thường yêu cầu xử lý theo thời gian gần thực. Để khai thác giá trị của dữ liệu này, hệ thống không chỉ cần lưu trữ hoặc truyền tải, mà còn phải hiểu được nội dung bên trong ảnh/video như đối tượng, cảnh, hành vi, quan hệ không gian và các sự kiện đáng chú ý. Các nghiên cứu về edge computing và fog computing cho thấy việc đưa xử lý đến gần nguồn dữ liệu là hướng phù hợp với các ứng dụng cần độ trễ thấp, nhận biết vị trí và xử lý dòng dữ liệu liên tục [1,2].

Cloud computing cung cấp năng lực tính toán mạnh, khả năng mở rộng linh hoạt và phù hợp với các mô hình học sâu quy mô lớn [3]. Tuy nhiên, việc truyền toàn bộ dữ liệu hình ảnh/video lên cloud có thể gây tăng độ trễ, tiêu tốn băng thông, phát sinh chi phí và làm nảy sinh yêu cầu bảo mật dữ liệu. Edge computing đưa một phần năng lực xử lý về gần nguồn dữ liệu, giúp giảm tải mạng và phản hồi nhanh hơn [1,4]. Mô hình edge–cloud computing kết hợp hai hướng tiếp cận này, trong đó edge đảm nhiệm thu thập, tiền xử lý, lọc dữ liệu, suy luận nhanh; cloud đảm nhiệm xử lý sâu, huấn luyện/cập nhật mô hình, lưu trữ và phân tích tổng hợp.

Bài tiểu luận tập trung nghiên cứu mô hình edge–cloud computing cho truyền thông đa phương tiện và phân tích ngữ nghĩa dữ liệu hình ảnh lớn. Trọng tâm của bài là xây dựng một kiến trúc logic có thể triển khai thực nghiệm, đề xuất quy trình xử lý ảnh/video từ tầng edge đến cloud, phân tích các kỹ thuật chính, đồng thời đưa ra tiêu chí đánh giá hiệu quả hệ thống.

# CHƯƠNG 1: TỔNG QUAN VÀ XÁC ĐỊNH BÀI TOÁN NGHIÊN CỨU

## 1.1. Bối cảnh hình thành đề tài

Trong môi trường truyền thông đa phương tiện hiện đại, dữ liệu hình ảnh và video không còn chỉ được lưu trữ để xem lại, mà trở thành nguồn dữ liệu đầu vào cho các hệ thống phân tích thông minh. Camera giám sát, thiết bị di động, cảm biến IoT, nền tảng mạng xã hội, hệ thống giao thông thông minh và các kho ảnh số tạo ra lượng dữ liệu rất lớn theo thời gian thực. Để khai thác giá trị của dữ liệu này, hệ thống cần chuyển đổi dữ liệu ảnh/video thô thành thông tin có ý nghĩa như đối tượng xuất hiện, bối cảnh, hành vi, sự kiện, mức độ bất thường, từ khóa tìm kiếm và metadata phục vụ báo cáo.


Mô hình xử lý tập trung trên cloud có ưu điểm về năng lực tính toán, khả năng mở rộng và phù hợp với các mô hình học sâu lớn [3]. Tuy nhiên, khi dữ liệu đầu vào là ảnh độ phân giải cao hoặc video liên tục, việc truyền toàn bộ dữ liệu lên cloud có thể tạo ra độ trễ lớn, tiêu tốn băng thông, tăng chi phí lưu trữ và làm phát sinh rủi ro riêng tư dữ liệu. Edge computing đưa một phần xử lý về gần nguồn dữ liệu, giúp giảm độ trễ và giảm lượng dữ liệu cần truyền [1, 4]. Tuy vậy, thiết bị edge thường hạn chế về CPU, GPU, RAM, năng lượng và dung lượng lưu trữ. Vì vậy, cách tiếp cận hợp lý là phối hợp giữa edge và cloud: edge xử lý nhanh các tác vụ nhẹ và dữ liệu rõ ràng, còn cloud xử lý các trường hợp khó, huấn luyện mô hình và phân tích tổng hợp.

## 1.2. Phát biểu bài toán nghiên cứu

Bài toán trung tâm của đề tài được phát biểu như sau: *Làm thế nào để thiết kế một mô hình edge–cloud computing cho phép phân tích ngữ nghĩa dữ liệu hình ảnh/video lớn trong truyền thông đa phương tiện, đồng thời cân bằng được ba yếu tố quan*

*trọng: độ trễ xử lý, băng thông truyền tải và độ chính xác phân tích?*

Cụ thể, hệ thống đầu vào gồm nhiều nguồn ảnh/video như camera, kho ảnh, thiết bị di động hoặc luồng dữ liệu từ ứng dụng. Mỗi ảnh hoặc khung hình video cần được xử lý để tạo ra kết quả ngữ nghĩa gồm nhãn đối tượng, vùng chứa đối tượng, độ tin cậy, metadata, embedding phục vụ tìm kiếm và cảnh báo sự kiện. Nếu toàn bộ dữ liệu được gửi lên cloud, độ chính xác có thể cao nhưng độ trễ và băng thông lớn. Nếu toàn bộ dữ liệu được xử lý tại edge, độ trễ thấp nhưng độ chính xác có thể giảm do mô hình nhẹ. Vì vậy, bài toán không chỉ là lựa chọn mô hình AI, mà là bài toán phân phối tác vụ xử lý giữa edge và cloud.



Hình 1.1: Mô tả bài toán nghiên cứu của đề tài

### 1.3. Đối tượng, phạm vi và giả định nghiên cứu

#### 1.3.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là mô hình xử lý phân tán giữa edge và cloud cho dữ liệu ảnh/video trong truyền thông đa phương tiện. Trọng tâm không phải là xây dựng một mô hình thị giác máy tính mới hoàn toàn, mà là nghiên cứu cách tổ chức hệ thống, cách phân chia xử lý, cách quyết định offloading và cách đánh giá hiệu quả của mô hình phối hợp.

#### 1.3.2. Phạm vi nghiên cứu

Phạm vi của đề tài gồm các nội dung sau:

- Phân tích dữ liệu đầu vào là ảnh tĩnh, khung hình video hoặc luồng video từ camera.
- Tập trung vào các tác vụ phát hiện đối tượng, tạo metadata ngữ nghĩa, trích xuất embedding và tìm kiếm ngữ nghĩa.
- Thiết kế kiến trúc edge–cloud gồm nguồn dữ liệu, edge node, cloud server, kho metadata và dashboard/API ứng dụng.
- Đề xuất cơ chế offloading dựa trên độ tin cậy của mô hình, độ phức tạp cảnh, tải edge và trạng thái mạng.
- Đưa ra phương án thực nghiệm có thể triển khai bằng Docker, Python, OpenCV, mô hình YOLO nhẹ ở edge và mô hình mạnh hơn ở cloud.

Đề tài không đi sâu vào huấn luyện từ đầu một mô hình học sâu quy mô lớn, không triển khai trên hệ thống camera thật quy mô thành phố và không xử lý đầy đủ tất cả dạng dữ liệu đa phương tiện như âm thanh hay văn bản. Tuy nhiên, mô hình đề xuất có thể mở rộng sang các dạng dữ liệu này trong hướng phát triển tiếp theo.

### ***1.3.3. Giả định nghiên cứu***

Để mô hình nghiên cứu có thể thực nghiệm trong phạm vi học phần, đề tài đặt ra một số giả định:

- Edge node có tài nguyên hạn chế hơn cloud, có thể là máy tính mini, Raspberry Pi, Jetson Nano hoặc một máy ảo/container được giới hạn CPU/RAM.
- Cloud node có năng lực tính toán mạnh hơn, có thể chạy mô hình lớn hơn hoặc xử lý batch nhiều yêu cầu.
- Mạng giữa edge và cloud có độ trễ và băng thông có thể đo được, có thể giả lập bằng giới hạn tốc độ mạng.



- Dữ liệu thử nghiệm có nhãn để đánh giá độ chính xác, hoặc có thể dùng bộ dữ liệu chuẩn như COCO [5].

## **1.4. Mục tiêu nghiên cứu**

### ***1.4.1. Mục tiêu tổng quát***

Mục tiêu tổng quát của đề tài là xây dựng và đánh giá một mô hình edge–cloud computing cho phân tích ngữ nghĩa dữ liệu hình ảnh lớn trong truyền thông đa phương tiện, trong đó edge xử lý nhanh và giảm dữ liệu truyền tải, còn cloud đảm nhiệm phân tích sâu và quản lý tập trung.

### ***1.4.2. Mục tiêu cụ thể***

Các mục tiêu cụ thể gồm:

1. Hệ thống hóa cơ sở lý thuyết về cloud computing, edge computing, fog computing và collaborative inference.
2. Làm rõ đặc điểm của dữ liệu hình ảnh/video lớn và yêu cầu phân tích ngữ nghĩa trong truyền thông đa phương tiện.
3. Đề xuất kiến trúc hệ thống edge–cloud có thể triển khai thử nghiệm.
4. Xây dựng cơ chế quyết định offloading dựa trên ngưỡng tin cậy, tải tài nguyên và điều kiện mạng.
5. Thiết kế bộ kịch bản thực nghiệm so sánh cloud-only, edge-only và edge–cloud.
6. Đề xuất các chỉ số đánh giá gồm latency, bandwidth, accuracy, CPU/RAM/GPU, throughput và chi phí vận hành.
7. Phân tích khả năng ứng dụng trong giám sát video, giao thông thông minh, kho ảnh số, truyền thông số và tìm kiếm ngữ nghĩa.

## 1.5. Câu hỏi nghiên cứu và giả thuyết

| Mã  | Nội dung câu hỏi nghiên cứu                                                                                                                                         |
|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| RQ1 | Mô hình cloud-only, edge-only và edge–cloud khác nhau như thế nào về độ trễ, băng thông, độ chính xác và tài nguyên hệ thống?                                       |
| RQ2 | Edge có thể giảm lượng dữ liệu gửi lên cloud bằng các kỹ thuật tiền xử lý, lọc khung hình, cắt vùng quan tâm và gửi metadata đến mức nào?                           |
| RQ3 | Ngưỡng confidence và tải tài nguyên edge ảnh hưởng như thế nào đến quyết định offloading?                                                                           |
| RQ4 | Mô hình edge–cloud có thể đạt độ chính xác gần cloud-only nhưng giảm độ trễ và băng thông so với cloud-only hay không?                                              |
| RQ5 | Kiến trúc đề xuất có thể ứng dụng trong các hệ thống truyền thông đa phương tiện thực tế như giám sát video, giao thông thông minh và tìm kiếm ảnh/video hay không? |

Bảng 1.1: Câu hỏi nghiên cứu của đề tài

Từ các câu hỏi trên, đề tài đặt ra các giả thuyết nghiên cứu:

- **H1:** Edge–cloud có thể giảm băng thông truyền tải so với cloud-only nhờ chỉ gửi dữ liệu cần phân tích sâu.
- **H2:** Edge–cloud có thể giảm độ trễ trung bình so với cloud-only trong các trường hợp ảnh/video đơn giản được xử lý tại edge.
- **H3:** Edge–cloud có thể đạt độ chính xác cao hơn edge-only nhờ cloud xử lý lại các trường hợp có độ tin cậy thấp.
- **H4:** Cơ chế offloading thích hợp giúp hệ thống cân bằng tốt hơn giữa hiệu năng và chất lượng phân tích.

## **1.6. Đóng góp dự kiến của đề tài**

Đề tài có ba nhóm đóng góp chính. Thứ nhất, về mặt nghiên cứu, đề tài hệ thống hóa bài toán phân tích ngữ nghĩa hình ảnh lớn trong bối cảnh edge–cloud computing, làm rõ các biến số cần đánh giá và các ràng buộc của hệ thống. Thứ hai, về mặt kỹ thuật, đề tài đề xuất kiến trúc xử lý phân tầng gồm edge node, cloud node, kho metadata và dashboard/API, kèm theo cơ chế offloading có thể triển khai. Thứ ba, về mặt thực nghiệm, đề tài xây dựng phương án đánh giá định lượng để so sánh ba mô hình cloud-only, edge-only và edge–cloud theo nhiều chỉ số.

## **1.7. Kết luận chương 1**

Chương 1 đã làm rõ bối cảnh, phát biểu bài toán, phạm vi, mục tiêu, câu hỏi nghiên cứu, giả thuyết và đóng góp dự kiến của đề tài. Điểm trọng tâm là bài toán không chỉ nằm ở mô hình AI nhận dạng ảnh, mà nằm ở thiết kế hệ thống xử lý phân tán sao cho dữ liệu được phân tích đúng nơi, đúng mức và đúng thời điểm. Đây là cơ sở để chương tiếp theo trình bày các nền tảng kỹ thuật phục vụ xây dựng mô hình.

## **CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN**

### **2.1. Cloud computing trong xử lý đa phương tiện**

Cloud computing cung cấp tài nguyên tính toán và lưu trữ thông qua các trung tâm dữ liệu lớn. Trong các bài toán xử lý ảnh/video, cloud thường được dùng để lưu trữ dữ liệu lớn, huấn luyện mô hình học sâu, chạy mô hình nhận dạng phức tạp và cung cấp API phân tích nội dung cho nhiều người dùng [3]. Ưu điểm của cloud là năng lực tính toán cao, khả năng mở rộng tốt và dễ quản trị tập trung. Tuy nhiên, cloud-only gặp hạn chế khi dữ liệu phát sinh ở xa trung tâm xử lý hoặc khi ứng dụng yêu cầu phản hồi nhanh.

Với dữ liệu video, chi phí truyền tải là vấn đề đáng kể. Nếu mỗi camera liên tục truyền luồng video độ phân giải cao lên cloud, hệ thống mạng sẽ bị tải lớn, trong khi nhiều khung hình có thể không chứa thông tin mới. Ngoài ra, dữ liệu hình ảnh có thể chứa thông tin nhạy cảm như khuôn mặt, biển số xe hoặc không gian riêng tư, làm phát sinh yêu cầu kiểm soát dữ liệu trước khi đưa lên cloud.

### **2.2. Edge computing và fog computing**

Edge computing là mô hình đưa tính toán đến gần nguồn phát sinh dữ liệu. Theo Shi và cộng sự, edge computing hướng đến xử lý dữ liệu ở biên mạng nhằm giảm độ trễ, giảm tải mạng và hỗ trợ các ứng dụng IoT [1]. Satyanarayanan cũng nhấn mạnh edge computing là hướng tiếp cận quan trọng khi các ứng dụng cần độ trễ thấp và nhận biết ngữ cảnh [4]. Fog computing mở rộng ý tưởng này bằng cách bổ sung tầng trung gian giữa thiết bị đầu cuối và cloud, giúp xử lý, lưu trữ và điều phối dịch vụ ở gần người dùng hơn [2].

Trong hệ thống đa phương tiện, edge có thể thực hiện các tác vụ như giải mã video,

trích xuất khung hình, phát hiện chuyển động, giảm kích thước ảnh, nhận dạng đối tượng bằng mô hình nhẹ và gửi kết quả ngữ nghĩa lên cloud. Điều này đặc biệt phù hợp với các bài toán giám sát, giao thông, sản xuất thông minh và phân tích nội dung thời gian thực.

### **2.3. Collaborative inference giữa edge và cloud**

Collaborative inference là hướng nghiên cứu phân chia quá trình suy luận của mô hình học sâu giữa thiết bị biên và cloud. Thay vì chạy toàn bộ mô hình ở một nơi, hệ thống có thể chạy một phần ở edge và một phần ở cloud, hoặc chạy mô hình nhẹ tại edge trước rồi chỉ gửi trường hợp khó lên cloud. Neurosurgeon là một trong những nghiên cứu tiêu biểu về phối hợp suy luận giữa mobile edge và cloud, trong đó vị trí phân tách mô hình được chọn theo độ trễ và tài nguyên [6]. Distributed Deep Neural Networks cũng cho thấy việc phân bố mạng nơ-ron trên end device, edge và cloud là hướng phù hợp cho các hệ thống phân tán [7].

Trong phạm vi đề tài, collaborative inference được áp dụng theo cách dễ triển khai hơn: edge chạy mô hình nhẹ để suy luận ban đầu; nếu confidence cao, kết quả được chấp nhận; nếu confidence thấp hoặc cảnh phức tạp, dữ liệu được gửi lên cloud để xử lý bằng mô hình mạnh hơn. Cách này phù hợp với điều kiện thực nghiệm của một báo cáo học phần vì không yêu cầu can thiệp sâu vào cấu trúc bên trong của mô hình DNN.

### **2.4. Phân tích ngữ nghĩa dữ liệu hình ảnh**

Phân tích ngữ nghĩa dữ liệu hình ảnh là quá trình chuyển đổi dữ liệu ảnh/video thô thành thông tin có ý nghĩa. Các cấp độ phân tích thường gồm:

- **Phát hiện đối tượng:** xác định đối tượng và vị trí trong ảnh.
- **Phân loại ảnh:** gán ảnh vào một hoặc nhiều nhóm nội dung.
- **Phân đoạn ảnh:** xác định vùng pixel tương ứng với từng lớp đối tượng.

- **Trích xuất embedding:** biểu diễn ảnh bằng vector đặc trưng để phục vụ tìm kiếm.
- **Tìm kiếm ngữ nghĩa:** tìm ảnh/video theo ý nghĩa nội dung thay vì chỉ theo tên tệp.
- **Phát hiện sự kiện:** xác định hành vi, tình huống hoặc bất thường trong ảnh/video.

Các mô hình học sâu như CNN, ResNet và YOLO đã tạo nền tảng cho xử lý ảnh hiện đại [8–10]. Các mô hình thị giác–ngôn ngữ như CLIP mở rộng khả năng liên kết ảnh với văn bản, hỗ trợ tìm kiếm ngữ nghĩa và phân loại zero-shot [11]. Trong hệ thống đề xuất, YOLO có thể dùng cho phát hiện đối tượng, còn embedding có thể dùng cho tìm kiếm ảnh tương đồng.

## 2.5. Các mô hình triển khai: cloud-only, edge-only và edge–cloud

Để đánh giá mô hình đề xuất, cần làm rõ ba mô hình triển khai đối chứng.

| <b>Tiêu chí</b>  | <b>Cloud-only</b>                       | <b>Edge-only</b>          | <b>Edge–cloud</b>                            |
|------------------|-----------------------------------------|---------------------------|----------------------------------------------|
| Vị trí xử lý     | Cloud xử lý gần như toàn bộ             | Edge xử lý toàn bộ        | Edge xử lý sơ bộ, cloud xử lý trường hợp khó |
| Độ trễ           | Phụ thuộc truyền dữ liệu lên cloud      | Thấp nếu mô hình nhẹ      | Linh hoạt, giảm độ trễ trung bình            |
| Băng thông       | Cao do gửi dữ liệu thô                  | Thấp                      | Trung bình đến thấp, tùy offloading          |
| Độ chính xác     | Cao nếu dùng mô hình lớn                | Có thể thấp hơn           | Gần cloud-only nếu offloading tốt            |
| Tài nguyên edge  | Thấp                                    | Cao hơn                   | Trung bình                                   |
| Tài nguyên cloud | Cao                                     | Thấp                      | Phụ thuộc tỷ lệ offload                      |
| Phù hợp          | Phân tích batch, không yêu cầu realtime | Tác vụ đơn giản, mạng yếu | Ứng dụng realtime có yêu cầu chính xác       |

Bảng 2.1: So sánh ba mô hình triển khai xử lý ảnh/video

## 2.6. Tổng quan nghiên cứu liên quan

Các nghiên cứu liên quan có thể chia thành bốn nhóm. Nhóm thứ nhất nghiên cứu nền tảng edge/fog computing, nhấn mạnh việc đưa xử lý đến gần nguồn dữ liệu để giảm độ trễ và hỗ trợ IoT [1,2,4]. Nhóm thứ hai nghiên cứu collaborative inference, trong đó tác vụ suy luận được phân phối giữa thiết bị, edge và cloud [6,7,12]. Nhóm thứ ba nghiên cứu mô hình thị giác máy tính như YOLO, ResNet, MobileNet và CLIP phục vụ phát hiện đối tượng, phân loại ảnh và tìm kiếm ngữ nghĩa [9–11, 13]. Nhóm thứ tư nghiên cứu các hệ thống end–edge–cloud quy mô lớn cho học

sâu, nhấn mạnh việc đánh giá đồng thời latency, accuracy, communication cost và scalability [14].

Khoảng trống nghiên cứu trong phạm vi đề tài là cần một mô hình thực nghiệm rõ ràng, vừa đủ đơn giản để triển khai trong điều kiện học phần, vừa đủ thể hiện bản chất của edge–cloud: có nguồn dữ liệu, edge node, cloud node, cơ chế offloading, bộ chỉ số đánh giá và kịch bản ứng dụng. Vì vậy, chương 3 sẽ đề xuất mô hình nghiên cứu cụ thể có thể triển khai bằng các công cụ phổ biến.

## **2.7. Kết luận chương 2**

Chương 2 đã trình bày các nền tảng kỹ thuật liên quan đến cloud computing, edge computing, fog computing, collaborative inference và phân tích ngữ nghĩa dữ liệu hình ảnh. Các nghiên cứu liên quan cho thấy edge–cloud không chỉ là xu hướng hạ tầng, mà còn là phương pháp thiết kế hệ thống phù hợp cho các bài toán đa phương tiện yêu cầu độ trễ thấp, tiết kiệm băng thông và duy trì độ chính xác. Đây là cơ sở để xây dựng kiến trúc đề xuất ở chương tiếp theo.



## **CHƯƠNG 3: MÔ HÌNH NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG ĐỀ XUẤT**

### **3.1. Quan điểm thiết kế mô hình**

Mô hình đề xuất được thiết kế theo nguyên tắc xử lý phân tầng. Dữ liệu không được gửi toàn bộ lên cloud ngay từ đầu, mà được đánh giá tại edge để xác định giá trị thông tin và mức độ cần thiết của phân tích sâu. Edge đóng vai trò là lớp lọc thông minh, trong khi cloud đóng vai trò là lớp xử lý nâng cao và quản lý tập trung. Quan điểm này phù hợp với các nghiên cứu về edge intelligence và collaborative DNN inference [12, 14].

Mục tiêu của thiết kế không phải loại bỏ cloud, mà giảm sự phụ thuộc vào cloud trong các trường hợp không cần thiết. Đồng thời, mô hình cũng không ép edge xử lý mọi thứ, vì điều này có thể làm giảm độ chính xác và gây quá tải thiết bị. Hệ thống cần một bộ quyết định offloading để xác định dữ liệu nào xử lý tại edge, dữ liệu nào gửi cloud và dữ liệu nào chỉ lưu metadata.

### **3.2. Yêu cầu chức năng và phi chức năng**

#### **3.2.1. Yêu cầu chức năng**

Hệ thống cần đáp ứng các chức năng sau:

1. Thu thập ảnh/video từ camera, tệp ảnh hoặc dataset.
2. Tiền xử lý ảnh/video tại edge: resize, normalize, sampling, nén, cắt vùng quan tâm.
3. Chạy mô hình phát hiện đối tượng nhẹ tại edge.
4. Tính confidence, số lượng đối tượng, độ phức tạp cảnh và tải tài nguyên.


5. Quyết định xử lý tại edge hoặc offload lên cloud.
6. Cloud chạy mô hình mạnh hơn, tạo metadata và embedding.
7. Lưu kết quả vào cơ sở dữ liệu metadata và kho vector.
8. Cung cấp dashboard giám sát, API tìm kiếm và báo cáo thống kê.

### 3.2.2. *Yêu cầu phi chức năng*

- **Hiệu năng:** độ trễ xử lý phải đủ thấp cho ứng dụng gần thời gian thực.
- **Mở rộng:** có thể bổ sung nhiều edge node hoặc nhiều nguồn dữ liệu.
- **Độ tin cậy:** edge cần xử lý tạm thời khi mất kết nối cloud.
- **Bảo mật:** dữ liệu truyền giữa edge và cloud cần xác thực và mã hóa.
- **Quan sát được:** hệ thống cần ghi log, đo metric và hỗ trợ truy vết kết quả.
- **Dễ triển khai:** ưu tiên kiến trúc container hóa để có thể lặp lại thực nghiệm.

### 3.3. Kiến trúc tổng thể


Kiến trúc đề xuất gồm bốn lớp: lớp nguồn dữ liệu, lớp edge, lớp cloud và lớp ứng dụng. Lớp nguồn dữ liệu bao gồm camera/video stream, kho ảnh lớn và thiết bị di động/IoT. Lớp edge thực hiện thu thập, tiền xử lý, suy luận nhanh và quyết định offloading. Lớp cloud thực hiện suy luận nâng cao, huấn luyện/cập nhật mô hình, lưu trữ ảnh/metadata và tạo embedding. Lớp ứng dụng cung cấp dashboard, API phân tích, tìm kiếm ngữ nghĩa, cảnh báo và báo cáo.



Hình 3.1: Kiến trúc edge–cloud đề xuất cho phân tích ngữ nghĩa dữ liệu hình ảnh lớn

### 3.4. Luồng xử lý dữ liệu

Luồng xử lý của hệ thống gồm sáu bước chính. Thứ nhất, edge nhận dữ liệu ảnh/video từ nguồn. Thứ hai, edge thực hiện tiền xử lý như trích xuất khung hình, resize, chuẩn hóa, lọc nhiễu và nén. Thứ ba, mô hình nhẹ tại edge chạy suy luận ban đầu để phát hiện đối tượng và tính confidence. Thứ tư, bộ quyết định offloading đánh giá kết quả. Thứ năm, nếu cần, dữ liệu được gửi lên cloud để xử lý bằng mô hình mạnh hơn. Thứ sáu, kết quả cuối cùng được lưu dưới dạng metadata, embedding và được hiển thị trên dashboard.



Hình 3.2: Quy trình xử lý và quyết định offloading

### 3.5. Mô hình dữ liệu ngữ nghĩa

Kết quả phân tích không chỉ là ảnh đã được nhận dạng, mà là một cấu trúc metadata có thể lưu trữ, tìm kiếm và phân tích. Mỗi ảnh hoặc khung hình có thể được mô tả bởi các trường sau:

- **frame\_id**: mã định danh ảnh hoặc khung hình.
- **source\_id**: mã nguồn dữ liệu, ví dụ camera hoặc dataset.
- **timestamp**: thời điểm thu thập.
- **objects**: danh sách đối tượng phát hiện được, gồm nhãn, bounding box và confidence.
- **scene\_tags**: nhãn bối cảnh như đường phố, phòng họp, bãi xe hoặc khu vực đông người.
- **embedding**: vector đặc trưng phục vụ tìm kiếm tương đồng.
- **processing\_place**: nơi xử lý chính, gồm edge, cloud hoặc hybrid.

- **latency**: thời gian xử lý từ lúc nhận dữ liệu đến khi có kết quả.

Mô hình dữ liệu này giúp hệ thống không chỉ phát hiện đối tượng, mà còn hỗ trợ truy vấn như: tìm tất cả khung hình có xe máy, tìm ảnh có người xuất hiện trong khu vực cổng, tìm ảnh tương đồng với ảnh mẫu hoặc thống kê tần suất đối tượng theo thời gian.

### 3.6. Cơ chế offloading đề xuất

Bộ quyết định offloading là thành phần quan trọng nhất của mô hình. Quyết định có thể dựa trên bốn nhóm thông tin: kết quả suy luận tại edge, tài nguyên của edge, trạng thái mạng và chính sách ứng dụng. Trong phạm vi thực nghiệm, đề tài đề xuất quy tắc quyết định dựa trên confidence, số lượng đối tượng và tải edge.

$$D(x) = \begin{cases} \text{Edge,} & \text{nếu } c_{\max}(x) \geq \tau_c \text{ và } U_{\text{edge}} \leq \tau_u \\ \text{Cloud,} & \text{nếu } c_{\max}(x) < \tau_c \text{ hoặc } U_{\text{edge}} > \tau_u \\ \text{Cloud,} & \text{nếu } N_{\text{obj}}(x) > \tau_n \text{ hoặc cảnh phức tạp} \end{cases}$$

Trong đó,  $c_{\max}(x)$  là confidence cao nhất hoặc confidence trung bình của các đối tượng trong ảnh  $x$ ;  $U_{\text{edge}}$  là mức sử dụng tài nguyên edge;  $N_{\text{obj}}(x)$  là số đối tượng phát hiện được;  $\tau_c$ ,  $\tau_u$  và  $\tau_n$  lần lượt là ngưỡng confidence, ngưỡng tải và ngưỡng số đối tượng.

| Điều kiện                                       | Quyết định                   | Lý do                                       |
|-------------------------------------------------|------------------------------|---------------------------------------------|
| Confidence cao, edge còn tài nguyên             | Xử lý tại edge               | Kết quả đủ tin cậy, không cần gửi cloud     |
| Confidence thấp                                 | Gửi cloud                    | Ảnh khó, cần mô hình mạnh hơn               |
| Cảnh có nhiều đối tượng nhỏ                     | Gửi cloud                    | Mô hình nhẹ có thể bỏ sót chi tiết          |
| Mạng cloud yếu nhưng sự kiện không nghiêm trọng | Xử lý tạm tại edge           | Duy trì hoạt động khi kết nối không ổn định |
| Sự kiện quan trọng hoặc cảnh báo an toàn        | Gửi cloud ưu tiên            | Cần xác minh bằng mô hình chính xác hơn     |
| Dữ liệu nhạy cảm                                | Xử lý/ẩn danh tại edge trước | Giảm rủi ro riêng tư dữ liệu                |

Bảng 3.1: Quy tắc offloading đề xuất

### 3.7. Thuật toán xử lý đề xuất

Thuật toán tổng quát có thể mô tả như sau:

1. Nhận ảnh hoặc khung hình video  $x$  tại edge.
2. Tiền xử lý  $x$  để tạo ảnh chuẩn hóa  $x'$ .
3. Chạy mô hình nhẹ  $M_e$  tại edge để thu được nhãn, bounding box và confidence.
4. Tính các đại lượng  $c_{\max}$ ,  $N_{obj}$ ,  $U_{edge}$  và trạng thái mạng.
5. Nếu điều kiện edge đạt yêu cầu, lưu metadata và trả kết quả tại edge.
6. Ngược lại, gửi ảnh nén, vùng quan tâm hoặc metadata lên cloud.
7. Cloud chạy mô hình mạnh  $M_c$ , tạo kết quả cuối cùng và embedding.

8. Lưu kết quả vào kho metadata, cập nhật dashboard và API tìm kiếm.

### **3.8. Kết luận chương 3**

Chương 3 đã đề xuất mô hình nghiên cứu và kiến trúc hệ thống edge–cloud cho phân tích ngữ nghĩa dữ liệu hình ảnh lớn. Điểm chính của kiến trúc là sử dụng edge như lớp xử lý và lọc thông minh, cloud như lớp phân tích sâu và quản lý tập trung. Cơ chế offloading dựa trên confidence, tải tài nguyên và độ phức tạp cảnh giúp mô hình có khả năng cân bằng giữa độ trễ, băng thông và độ chính xác.

## **CHƯƠNG 4: THIẾT KẾ THỰC NGHIỆM VÀ PHƯƠNG PHÁP ĐÁNH GIÁ**

### **4.1. Mục tiêu thực nghiệm**

Thực nghiệm được thiết kế nhằm kiểm chứng các giả thuyết nghiên cứu đã nêu ở chương 1. Mục tiêu không phải chứng minh một mô hình AI mới tốt hơn mọi mô hình hiện có, mà là đánh giá hiệu quả của kiến trúc edge–cloud khi so sánh với cloud-only và edge-only. Cụ thể, thực nghiệm cần trả lời các câu hỏi:

- Edge–cloud giảm được bao nhiêu phần trăm dữ liệu gửi lên cloud?
- Độ trễ trung bình của edge–cloud thấp hơn cloud-only hay không?
- Độ chính xác của edge–cloud có gần cloud-only và cao hơn edge-only không?
- Khi thay đổi ngưỡng confidence, tỷ lệ offload và kết quả đánh giá thay đổi như thế nào?

### **4.2. Môi trường thực nghiệm đề xuất**

Môi trường thực nghiệm có thể triển khai theo hai mức: mức tối thiểu và mức mở rộng. Mức tối thiểu dùng một máy tính cá nhân chạy Docker, trong đó edge và cloud là hai container được giới hạn tài nguyên khác nhau. Mức mở rộng dùng một thiết bị edge thật như Raspberry Pi hoặc Jetson Nano và một server cloud/GPU riêng.



| Thành phần    | Cấu hình tối thiểu                           | Cấu hình mở rộng                         |
|---------------|----------------------------------------------|------------------------------------------|
| Edge node     | Docker container giới hạn 2 CPU, 2–4 GB RAM  | Raspberry Pi 4, Jetson Nano hoặc mini PC |
| Cloud node    | Docker container 4–8 CPU, 8–16 GB RAM        | Server GPU hoặc máy trạm có CUDA         |
| Mô hình edge  | YOLO-small/nano hoặc MobileNet               | YOLOv8n, YOLOv8s, TensorRT/ONNX          |
| Mô hình cloud | YOLO-medium/large hoặc mô hình chính xác hơn | YOLOv8m/l, Faster R-CNN, CLIP embedding  |
| Dữ liệu       | Tập ảnh COCO subset hoặc video mẫu           | Camera/video thực tế, dataset lớn hơn    |
| Công cụ đo    | Python time, psutil, log API                 | Prometheus, Grafana, message queue       |

Bảng 4.1: Môi trường thực nghiệm đề xuất

### 4.3. Dữ liệu thực nghiệm

Dữ liệu thực nghiệm có thể sử dụng ba nguồn. Nguồn thứ nhất là tập ảnh chuẩn COCO, phù hợp để đánh giá phát hiện đối tượng vì có nhãn và bounding box [5]. Nguồn thứ hai là video mẫu được trích xuất thành khung hình theo chu kỳ. Nguồn thứ ba là tập ảnh tự thu thập từ môi trường ứng dụng, ví dụ ảnh giao thông, ảnh khuôn viên, ảnh kho bãi hoặc ảnh camera văn phòng. Với phạm vi báo cáo học phần, có thể chọn subset từ 1.000 đến 5.000 ảnh để giảm thời gian xử lý nhưng vẫn đủ để so sánh.

Dữ liệu nên được chia thành các nhóm theo độ phức tạp:

- **Nhóm đơn giản:** ít đối tượng, đối tượng rõ, ánh sáng tốt.

- **Nhóm trung bình:** nhiều đối tượng, bối cảnh phức tạp vừa phải.
- **Nhóm khó:** đối tượng nhỏ, bị che khuất, ánh sáng yếu hoặc nhiều chuyển động.

Cách chia này giúp kiểm tra xem cơ chế offloading có thực sự gửi các trường hợp khó lên cloud hay không.

#### 4.4. Các mô hình đối chứng

Thực nghiệm so sánh ba mô hình:

1. **Cloud-only:** edge chỉ thu thập và gửi toàn bộ ảnh/video lên cloud; cloud chạy mô hình mạnh và trả kết quả.
2. **Edge-only:** edge xử lý toàn bộ bằng mô hình nhẹ; cloud không tham gia suy luận.
3. **Edge–cloud:** edge xử lý trước; chỉ ảnh hoặc khung hình có confidence thấp, cảnh phức tạp hoặc sự kiện quan trọng mới gửi cloud.

Mô hình cloud-only được dùng làm mốc về độ chính xác, mô hình edge-only được dùng làm mốc về độ trễ và băng thông, còn mô hình edge–cloud được kỳ vọng đạt cân bằng giữa hai mô hình này.

#### 4.5. Kịch bản thực nghiệm

##### 4.5.1. Kịch bản 1: So sánh độ trễ

Mỗi ảnh được đưa qua ba mô hình triển khai. Hệ thống ghi lại thời gian thu thập, tiền xử lý, suy luận edge, upload, suy luận cloud, download và hậu xử lý. Tổng độ

trễ được tính như sau:

$$T_{\text{total}} = T_{\text{capture}} + T_{\text{preprocess}} + T_{\text{edge}}^{\text{infer}} + T_{\text{upload}} \\ + T_{\text{cloud}}^{\text{infer}} + T_{\text{download}} + T_{\text{postprocess}}$$

Với edge-only, các thành phần upload, cloud inference và download gần như bằng 0. Với cloud-only, edge inference có thể không tồn tại nhưng upload tăng mạnh. Với edge-cloud, tổng độ trễ phụ thuộc vào tỷ lệ ảnh được offload.

#### 4.5.2. *Kịch bản 2: So sánh băng thông*

Băng thông được đo bằng tổng dung lượng dữ liệu gửi từ edge lên cloud. Tỷ lệ tiết kiệm băng thông được tính:

$$\eta_{\text{bw}} = 1 - \frac{S_{\text{uploaded}}}{S_{\text{raw}}}$$

Trong đó,  $S_{\text{raw}}$  là dung lượng dữ liệu thô nếu gửi toàn bộ lên cloud, còn  $S_{\text{uploaded}}$  là dung lượng thực tế được gửi trong mô hình edge-cloud.

#### 4.5.3. *Kịch bản 3: So sánh độ chính xác*

Độ chính xác được đánh giá bằng Precision, Recall, F1-score và mAP. Nếu sử dụng COCO subset, có thể đánh giá dựa trên nhãn chuẩn. Nếu sử dụng dữ liệu tự thu thập chưa có nhãn, có thể chọn một tập nhỏ để gán nhãn thủ công hoặc dùng cloud-only làm baseline tham chiếu.

#### 4.5.4. *Kịch bản 4: Thay đổi ngưỡng confidence*

Ngưỡng confidence  $\tau_c$  được thay đổi theo các mức 0.3, 0.5, 0.7 và 0.9. Khi  $\tau_c$  thấp, edge chấp nhận nhiều kết quả hơn, băng thông giảm nhưng có thể giảm độ chính xác. Khi  $\tau_c$  cao, nhiều ảnh được gửi cloud hơn, độ chính xác tăng nhưng độ trễ và băng thông cũng tăng. Kịch bản này giúp tìm điểm cân bằng phù hợp.

#### 4.5.5. Kịch bản 5: Giả lập mạng yếu

Độ trễ mạng và băng thông giữa edge và cloud được thay đổi để mô phỏng điều kiện mạng khác nhau. Mục tiêu là kiểm tra khả năng duy trì hoạt động của edge khi cloud không ổn định. Trong trường hợp mạng yếu, hệ thống có thể ưu tiên xử lý tại edge, lưu hàng đợi cục bộ và đồng bộ lại sau.

#### 4.6. Bộ chỉ số đánh giá

| Nhóm chỉ số      | Cách đo                                                                         | Ý nghĩa                                               |
|------------------|---------------------------------------------------------------------------------|-------------------------------------------------------|
| Latency          | Thời gian từ lúc hệ thống nhận ảnh hoặc khung hình đến khi có kết quả phân tích | Đánh giá khả năng đáp ứng thời gian thực của hệ thống |
| Upload bandwidth | Tổng dung lượng dữ liệu được gửi từ edge lên cloud trong quá trình xử lý        | Đánh giá khả năng giảm tải mạng truyền dẫn            |
| Throughput       | Số ảnh hoặc số khung hình được xử lý trong một giây                             | Đánh giá khả năng xử lý liên tục của hệ thống         |
| CPU/RAM/GPU      | Mức sử dụng tài nguyên tính toán tại edge node và cloud node                    | Đánh giá khả năng triển khai trong điều kiện thực tế  |
| Offload ratio    | Tỷ lệ ảnh hoặc khung hình được gửi lên cloud trên tổng dữ liệu đầu vào          | Đánh giá hành vi của bộ quyết định offloading         |

Bảng 4.2: Nhóm chỉ số đánh giá hiệu năng hệ thống

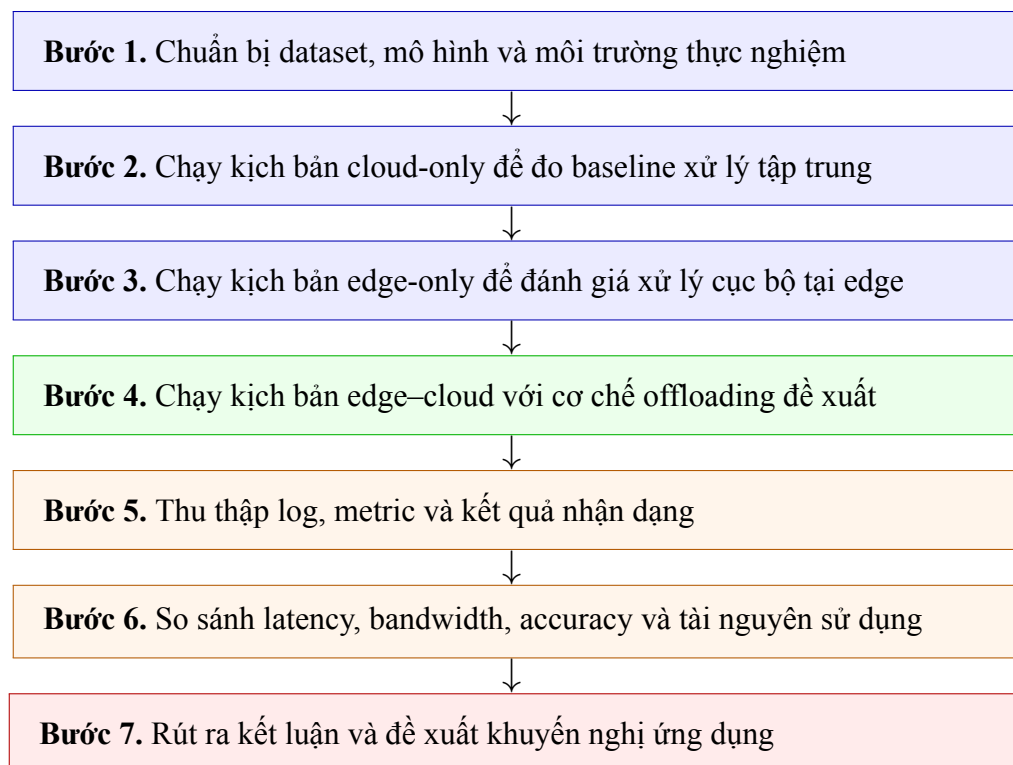
| Nhóm chỉ số | Cách đo                                                                           | Ý nghĩa                                                       |
|-------------|-----------------------------------------------------------------------------------|---------------------------------------------------------------|
| Precision   | Tỷ lệ kết quả dự đoán đúng trên tổng số kết quả được mô hình dự đoán              | Đánh giá mức độ chính xác của kết quả nhận dạng               |
| Recall      | Tỷ lệ đối tượng thực tế được mô hình phát hiện đúng                               | Đánh giá khả năng phát hiện đầy đủ các đối tượng cần quan tâm |
| F1-score    | Trung bình điều hòa giữa Precision và Recall                                      | Đánh giá cân bằng giữa độ chính xác và khả năng phát hiện     |
| mAP         | Giá trị mean Average Precision tính theo từng lớp đối tượng                       | Đánh giá hiệu quả tổng thể của tác vụ phát hiện đối tượng     |
| Cost proxy  | Thời gian xử lý trên cloud, dung lượng truyền tải và dung lượng lưu trữ phát sinh | Ước lượng chi phí vận hành của hệ thống                       |

Bảng 4.3: Nhóm chỉ số đánh giá chất lượng phân tích và chi phí

#### 4.7. Thiết kế dashboard và log thực nghiệm

Để thực nghiệm có tính quan sát và dễ đánh giá, hệ thống cần ghi log theo từng ảnh hoặc từng khung hình. Mỗi bản ghi gồm: thời gian nhận, thời gian tiền xử lý, kết quả edge, quyết định offloading, thời gian upload, kết quả cloud, độ trễ tổng, dung lượng truyền, tài nguyên edge và trạng thái mạng. Dashboard có thể hiển thị các biểu đồ như latency theo thời gian, tỷ lệ offload, băng thông tiết kiệm, số lượng đối tượng theo lớp và phân bố confidence.

#### 4.8. Quy trình thực nghiệm tổng quát



Hình 4.1: Quy trình thực nghiệm đề xuất

#### 4.9. Kết luận chương 4

Chương 4 đã trình bày thiết kế thực nghiệm chi tiết, bao gồm môi trường triển khai, dữ liệu, mô hình đối chứng, kịch bản đo lường và bộ chỉ số đánh giá. Với thiết kế

này, đề tài có thể tạo ra kết quả định lượng rõ ràng thay vì chỉ dừng ở mô tả lý thuyết. Các kết quả dự kiến và cách phân tích sẽ được trình bày ở chương 5.

## **CHƯƠNG 5: KHUNG ĐÁNH GIÁ, PHÂN TÍCH ĐỊNH TÍNH VÀ KHẢ NĂNG ỨNG DỤNG MÔ HÌNH**

### **5.1. Lý do lựa chọn đánh giá định tính**

Trong phạm vi bài tiểu luận, đề tài tập trung vào việc nghiên cứu, hệ thống hóa cơ sở lý thuyết và đề xuất mô hình edge–cloud computing cho truyền thông đa phương tiện và phân tích ngữ nghĩa dữ liệu hình ảnh lớn. Do chưa triển khai đầy đủ hệ thống thực nghiệm trên môi trường thật, chương này không trình bày số liệu đo đạc cụ thể như độ trễ tính bằng mili giây, dung lượng băng thông tiết kiệm hoặc độ chính xác mAP thực tế.

Thay vào đó, chương này trình bày khung đánh giá, phân tích định tính và các nhận định kỳ vọng dựa trên đặc điểm kỹ thuật của ba mô hình triển khai: cloud-only, edge-only và edge–cloud. Cách tiếp cận này giúp làm rõ giá trị nghiên cứu của mô hình đề xuất mà không sử dụng số liệu chưa được kiểm chứng.

### **5.2. Khung so sánh các mô hình triển khai**

Để đánh giá mô hình edge–cloud, đề tài sử dụng ba phương án triển khai làm cơ sở so sánh. Phương án cloud-only đại diện cho cách xử lý tập trung, trong đó toàn bộ dữ liệu ảnh hoặc video được gửi lên cloud. Phương án edge-only đại diện cho cách xử lý cục bộ, trong đó toàn bộ tác vụ phân tích được thực hiện tại edge. Phương án edge–cloud là mô hình đề xuất, trong đó edge thực hiện tiền xử lý và suy luận nhanh, còn cloud xử lý các trường hợp phức tạp hoặc có độ tin cậy thấp.

| <b>Tiêu chí</b>       | <b>Cloud-only</b>                                | <b>Edge-only</b>                          | <b>Edge-cloud</b>                                                            |
|-----------------------|--------------------------------------------------|-------------------------------------------|------------------------------------------------------------------------------|
| Độ trễ xử lý          | Có xu hướng cao do phải truyền dữ liệu lên cloud | Có xu hướng thấp nếu mô hình nhẹ          | Có khả năng cân bằng do ảnh đơn giản xử lý tại edge, ảnh khó gửi cloud       |
| Băng thông truyền tải | Cao vì thường gửi dữ liệu thô                    | Thấp vì xử lý cục bộ                      | Thấp hơn cloud-only do chỉ gửi dữ liệu cần phân tích sâu                     |
| Độ chính xác          | Có thể cao do dùng mô hình mạnh                  | Có thể giảm nếu edge dùng mô hình nhẹ     | Có thể gần cloud-only nếu cơ chế offloading hoạt động tốt                    |
| Tài nguyên edge       | Yêu cầu thấp                                     | Yêu cầu cao hơn                           | Yêu cầu trung bình, phụ thuộc mức xử lý tại edge                             |
| Tài nguyên cloud      | Yêu cầu cao                                      | Yêu cầu thấp                              | Phụ thuộc tỷ lệ dữ liệu được offload lên cloud                               |
| Khả năng mở rộng      | Phụ thuộc năng lực cloud và đường truyền         | Phụ thuộc số lượng và năng lực edge node  | Có khả năng mở rộng theo mô hình phân tán nhiều edge node                    |
| Phù hợp ứng dụng      | Phân tích batch, lưu trữ tập trung               | Ứng dụng đơn giản, yêu cầu phản hồi nhanh | Ứng dụng đa phương tiện cần cân bằng giữa độ trễ, băng thông và độ chính xác |

Bảng 5.1: Khung so sánh định tính giữa các mô hình triển khai



### **5.3. Phân tích định tính theo từng tiêu chí**

#### **5.3.1. Độ trễ xử lý**

Trong mô hình cloud-only, dữ liệu ảnh hoặc video cần được truyền từ nguồn phát sinh lên cloud trước khi xử lý. Do đó, tổng độ trễ không chỉ bao gồm thời gian suy luận của mô hình AI, mà còn bao gồm thời gian truyền dữ liệu, thời gian chờ xử lý trên cloud và thời gian trả kết quả. Với các luồng video lớn, thành phần truyền dữ liệu có thể trở thành nguyên nhân chính làm tăng độ trễ.

Trong mô hình edge-only, dữ liệu được xử lý trực tiếp gần nguồn phát sinh, nhờ đó có khả năng giảm độ trễ phản hồi. Tuy nhiên, nếu edge node có tài nguyên hạn chế hoặc phải xử lý nhiều luồng video đồng thời, hệ thống có thể bị nghẽn tại chính thiết bị edge.

Mô hình edge–cloud được kỳ vọng cân bằng hai hướng tiếp cận trên. Các ảnh hoặc khung hình đơn giản có thể được xử lý ngay tại edge, trong khi các trường hợp khó được gửi lên cloud. Vì vậy, độ trễ trung bình có khả năng thấp hơn cloud-only, nhưng vẫn giữ được khả năng xử lý nâng cao nhờ cloud.

#### **5.3.2. Băng thông truyền tải**

Cloud-only thường tiêu tốn nhiều băng thông do phải truyền ảnh hoặc video thô lên cloud. Điều này đặc biệt đáng chú ý với hệ thống có nhiều camera hoặc dữ liệu độ phân giải cao. Edge-only gần như không cần truyền dữ liệu lên cloud trong quá trình suy luận, nhưng lại hạn chế khả năng phân tích tập trung.

Trong mô hình edge–cloud, edge có thể lọc khung hình, nén ảnh, cắt vùng quan tâm hoặc chỉ gửi metadata trong các trường hợp không cần phân tích sâu. Nhờ vậy, mô hình này có khả năng giảm băng thông so với cloud-only mà vẫn giữ được vai trò của cloud trong các tác vụ phức tạp.

### **5.3.3. Độ chính xác phân tích**

Cloud-only có lợi thế về độ chính xác vì có thể sử dụng mô hình lớn, nhiều tham số và yêu cầu tài nguyên cao. Edge-only thường phải sử dụng mô hình nhẹ để phù hợp với tài nguyên hạn chế, do đó có thể bỏ sót đối tượng nhỏ hoặc nhận dạng kém trong các cảnh phức tạp.

Edge-cloud có thể cải thiện hạn chế này bằng cách sử dụng confidence score hoặc độ phức tạp cảnh để quyết định offloading. Khi mô hình tại edge không đủ tin cậy, dữ liệu được gửi lên cloud để phân tích lại bằng mô hình mạnh hơn. Do đó, mô hình edge-cloud được kỳ vọng có độ chính xác cao hơn edge-only và tiệm cận cloud-only trong nhiều trường hợp.

### **5.3.4. Tài nguyên tính toán**

Cloud-only giảm yêu cầu tài nguyên tại edge nhưng làm tăng tải xử lý tại cloud. Edge-only giảm phụ thuộc vào cloud nhưng yêu cầu edge phải đủ mạnh để xử lý liên tục. Edge-cloud phân phối tải giữa hai phía, trong đó edge xử lý các tác vụ nhẹ và cloud xử lý tác vụ nặng. Đây là hướng phù hợp với các hệ thống có nhiều nguồn dữ liệu phân tán.

### **5.3.5. Khả năng mở rộng**

Khi số lượng camera hoặc nguồn ảnh tăng, cloud-only có thể gặp vấn đề về băng thông và chi phí xử lý tập trung. Edge-only có thể mở rộng theo số lượng edge node, nhưng việc quản lý mô hình và cập nhật phần mềm trở nên phức tạp. Edge-cloud có khả năng mở rộng linh hoạt hơn vì mỗi edge node xử lý một phần dữ liệu tại chỗ, còn cloud tổng hợp metadata và xử lý các trường hợp cần thiết.

#### 5.4. Khung kết quả nếu triển khai thực nghiệm

Nếu hệ thống được triển khai thực nghiệm trong giai đoạn tiếp theo, kết quả nên được trình bày theo các nhóm chỉ số cụ thể. Bảng dưới đây không phải là số liệu thực nghiệm, mà là khuôn mẫu ghi nhận kết quả sau khi hệ thống được đo đạc.

| Chỉ số             | Cloud-only     | Edge-only      | Edge-cloud     |
|--------------------|----------------|----------------|----------------|
| Latency trung bình | Ghi sau khi đo | Ghi sau khi đo | Ghi sau khi đo |
| P95 latency        | Ghi sau khi đo | Ghi sau khi đo | Ghi sau khi đo |
| Dung lượng upload  | Ghi sau khi đo | Ghi sau khi đo | Ghi sau khi đo |
| Throughput         | Ghi sau khi đo | Ghi sau khi đo | Ghi sau khi đo |
| Precision          | Ghi sau khi đo | Ghi sau khi đo | Ghi sau khi đo |
| Recall             | Ghi sau khi đo | Ghi sau khi đo | Ghi sau khi đo |
| F1-score hoặc mAP  | Ghi sau khi đo | Ghi sau khi đo | Ghi sau khi đo |
| CPU/RAM/GPU usage  | Ghi sau khi đo | Ghi sau khi đo | Ghi sau khi đo |

Bảng 5.2: Khuôn mẫu ghi nhận kết quả thực nghiệm

#### 5.5. Giá trị nghiên cứu của mô hình đề xuất

Mặc dù chưa có số liệu thực nghiệm cụ thể, mô hình đề xuất vẫn có giá trị nghiên cứu ở ba điểm chính. Thứ nhất, mô hình làm rõ cách phân phối tác vụ xử lý ảnh/video giữa edge và cloud thay vì xử lý tập trung hoàn toàn. Thứ hai, mô hình đưa ra cơ chế offloading dựa trên confidence, tải tài nguyên và độ phức tạp của dữ liệu đầu vào. Thứ ba, mô hình xác định được bộ chỉ số đánh giá cần thiết để triển khai thực nghiệm trong tương lai.

Về mặt học thuật, đề tài không chỉ mô tả edge computing hoặc cloud computing một cách riêng lẻ, mà đặt chúng trong một bài toán cụ thể của truyền thông đa phương tiện: phân tích ngữ nghĩa dữ liệu hình ảnh lớn. Về mặt kỹ thuật, mô hình có thể chuyển thành hệ thống thử nghiệm bằng các công cụ phổ biến như Python, OpenCV, Docker, YOLO, API server và dashboard giám sát.

## **5.6. Khả năng ứng dụng thực tế**

Mô hình edge–cloud có thể ứng dụng trong nhiều hệ thống truyền thông đa phương tiện. Trong giám sát video thông minh, edge có thể phát hiện nhanh người, phương tiện hoặc sự kiện bất thường, trong khi cloud tổng hợp dữ liệu từ nhiều camera. Trong giao thông thông minh, edge xử lý tại nút giao để giảm độ trễ, còn cloud phân tích xu hướng lưu lượng. Trong kho ảnh số và truyền thông số, edge có thể tiền xử lý và gắn nhãn ban đầu, còn cloud tạo embedding phục vụ tìm kiếm ngữ nghĩa.

Những ứng dụng này cho thấy mô hình edge–cloud không chỉ có ý nghĩa lý thuyết, mà còn phù hợp với các bài toán thực tế có dữ liệu lớn, phân tán và cần xử lý gần thời gian thực.

## **5.7. Hạn chế của nghiên cứu**

Do giới hạn về thời gian và điều kiện triển khai, đề tài chưa thực hiện đo đạc trên hệ thống thật với nhiều edge node và nhiều luồng video đồng thời. Các phân tích trong chương này chủ yếu dựa trên cơ sở lý thuyết, đặc điểm kỹ thuật của mô hình và khung thực nghiệm được đề xuất. Vì vậy, các nhận định về hiệu năng cần được kiểm chứng thêm bằng thực nghiệm trong các nghiên cứu tiếp theo.

Ngoài ra, đề tài chưa đánh giá sâu các vấn đề như bảo mật truyền dữ liệu giữa edge và cloud, quản lý phiên bản mô hình AI, tối ưu năng lượng cho thiết bị edge và khả năng chịu lỗi khi mất kết nối mạng. Đây là các nội dung quan trọng cần tiếp tục nghiên cứu nếu mô hình được triển khai trong môi trường thực tế.

## **5.8. Kết luận chương 5**

Chương 5 đã trình bày khung đánh giá và phân tích định tính cho mô hình edge–cloud computing trong phân tích ngữ nghĩa dữ liệu hình ảnh lớn. Do chưa có hệ thống thực nghiệm hoàn chỉnh, chương này không sử dụng số liệu đo đạc cụ thể mà

tập trung làm rõ cách so sánh cloud-only, edge-only và edge–cloud theo các tiêu chí độ trễ, băng thông, độ chính xác, tài nguyên và khả năng mở rộng. Nội dung chương cũng chỉ ra giá trị nghiên cứu, khả năng ứng dụng và các hạn chế cần được kiểm chứng trong những nghiên cứu tiếp theo.

## **CHƯƠNG 6: KHẢ NĂNG TRIỂN KHAI VÀ ỨNG DỤNG THỰC TẾ**

### **6.1. Ứng dụng trong giám sát video thông minh**

Trong hệ thống giám sát video, edge node có thể đặt gần camera hoặc tại gateway cục bộ. Edge xử lý phát hiện người, phương tiện, chuyển động bất thường hoặc xâm nhập vùng cấm. Chỉ khi phát hiện sự kiện quan trọng hoặc kết quả không chắc chắn, dữ liệu mới được gửi lên cloud để phân tích sâu và lưu trữ dài hạn. Cách triển khai này phù hợp với tòa nhà, khu công nghiệp, trường học, bệnh viện và hệ thống camera công cộng.

### **6.2. Ứng dụng trong giao thông thông minh**

Trong giao thông thông minh, camera tại nút giao có thể ghi nhận mật độ phương tiện, loại phương tiện, ùn tắc, vi phạm làn đường hoặc tai nạn. Edge xử lý nhanh tại nút giao để hỗ trợ cảnh báo thời gian thực. Cloud tổng hợp dữ liệu từ nhiều nút giao để phân tích xu hướng, tối ưu đèn tín hiệu và tạo báo cáo quản lý. Đây là ứng dụng điển hình cần kết hợp độ trễ thấp tại edge và phân tích tổng hợp tại cloud.


### **6.3. Ứng dụng trong kho ảnh số và truyền thông số**

Các cơ quan truyền thông, doanh nghiệp nội dung số hoặc hệ thống quản lý tài sản số có thể sử dụng mô hình này để tự động gắn thẻ ảnh, phân loại nội dung, phát hiện trùng lặp, tìm kiếm ảnh theo ngữ nghĩa và tạo báo cáo. Edge có thể xử lý bước đầu khi ảnh được tải lên, cloud tạo embedding và chỉ mục tìm kiếm. Người dùng có thể tìm kiếm bằng các truy vấn như “ảnh có xe cứu hỏa”, “ảnh đông người”, hoặc “ảnh tương tự mẫu này”.

## 6.4. Ứng dụng trong công nghiệp và kho bãi

Trong nhà máy hoặc kho bãi, camera có thể giám sát dây chuyền sản xuất, phát hiện lỗi sản phẩm, kiểm tra an toàn lao động và theo dõi hàng hóa. Edge xử lý gần camera để phản hồi nhanh, ví dụ dừng băng chuyền khi phát hiện vật thể nguy hiểm. Cloud lưu trữ kết quả, phân tích tỷ lệ lỗi và hỗ trợ cải tiến quy trình.

## 6.5. Kiến trúc ứng dụng mẫu



Hình 6.1: Kiến trúc ứng dụng mẫu cho hệ thống phân tích ảnh/video edge-cloud

## 6.6. Lộ trình triển khai sản phẩm thử nghiệm

Để đề tài có sản phẩm rõ ràng, có thể triển khai theo bốn giai đoạn:

1. **Giai đoạn 1:** xây dựng pipeline xử lý ảnh đơn lẻ, chạy edge-only và cloud-only.
2. **Giai đoạn 2:** bổ sung bộ quyết định offloading và cơ chế gửi dữ liệu từ edge lên cloud.
3. **Giai đoạn 3:** xây dựng dashboard hiển thị kết quả, latency, băng thông và tỷ lệ offload.
4. **Giai đoạn 4:** thêm tìm kiếm ngữ nghĩa bằng embedding và đánh giá trên dataset lớn hơn.

## **6.7. Kết luận chương 6**

Chương 6 đã làm rõ khả năng ứng dụng của mô hình edge–cloud trong giám sát video, giao thông thông minh, kho ảnh số, truyền thông số và công nghiệp. Các ứng dụng này đều có điểm chung là dữ liệu ảnh/video lớn, cần xử lý nhanh tại nguồn nhưng vẫn cần cloud để phân tích sâu, quản lý tập trung và cung cấp dịch vụ tìm kiếm/nghiệp vụ.



## **CHƯƠNG 7: THÁCH THỨC, BẢO MẬT VÀ HƯỚNG PHÁT TRIỂN**

### **7.1. Thách thức về cân bằng độ trễ và độ chính xác**

Thách thức lớn nhất của mô hình edge–cloud là chọn đúng dữ liệu cần gửi lên cloud. Nếu gửi quá ít, hệ thống có thể bỏ sót các trường hợp khó. Nếu gửi quá nhiều, mô hình gần giống cloud-only và mất lợi thế về băng thông. Vì vậy, cần điều chỉnh ngưỡng confidence, ưu tiên theo loại sự kiện và kết hợp thêm các tín hiệu như tải edge, độ trễ mạng và mức độ quan trọng của nguồn dữ liệu.

### **7.2. Thách thức về quản lý mô hình**

Trong hệ thống có nhiều edge node, mỗi edge có thể dùng phiên bản mô hình khác nhau. Nếu không quản lý tốt, kết quả phân tích giữa các edge có thể không đồng nhất. Cloud nên đóng vai trò quản lý vòng đời mô hình: huấn luyện/cập nhật, kiểm thử, đóng gói, phân phối xuống edge và thu thập log để đánh giá drift. Đây là vấn đề quan trọng khi mở rộng từ demo sang hệ thống thực tế.

### **7.3. Bảo mật và riêng tư dữ liệu**

Dữ liệu hình ảnh có thể chứa thông tin cá nhân hoặc thông tin nhạy cảm. Vì vậy, mô hình đề xuất cần tích hợp bảo mật ngay từ thiết kế:

- Xác thực giữa edge node và cloud bằng API key, token hoặc chứng chỉ.
- Mã hóa dữ liệu truyền qua mạng bằng HTTPS/TLS.
- Ẩn danh hoặc làm mờ khuôn mặt/biên số tại edge trước khi gửi cloud.
- Phân quyền truy cập dashboard và API theo vai trò.

- Ghi log truy cập, log xử lý và log thay đổi mô hình.
- Quy định thời gian lưu trữ ảnh gốc, metadata và embedding.

#### 7.4. Hướng phát triển nghiên cứu

Các hướng phát triển tiếp theo gồm:

- **Offloading thích ứng:** sử dụng học máy hoặc học tăng cường để tự động chọn nơi xử lý.
- **Nén đặc trưng trung gian:** edge gửi feature hoặc embedding thay vì ảnh gốc để giảm băng thông.
- **Federated learning:** nhiều edge cùng cải thiện mô hình mà không cần gửi dữ liệu thô về cloud.
- **Tối ưu mô hình:** lượng tử hóa, pruning, ONNX hoặc TensorRT để tăng tốc suy luận tại edge.
- **Phân tích đa phương thức:** kết hợp ảnh, video, âm thanh và văn bản để hiểu nội dung sâu hơn.
- **Tìm kiếm ngữ nghĩa nâng cao:** dùng mô hình thị giác-ngôn ngữ để tìm kiếm bằng ngôn ngữ tự nhiên.

#### 7.5. Kết luận chương 7

Chương 7 đã phân tích các thách thức về độ trễ, độ chính xác, quản lý mô hình, bảo mật và riêng tư dữ liệu. Các hướng phát triển như offloading thích ứng, federated learning và tìm kiếm đa phương thức cho thấy đề tài có khả năng mở rộng thành nghiên cứu sâu hơn hoặc sản phẩm thử nghiệm hoàn chỉnh.

## **CHƯƠNG 8: KẾT LUẬN**

### **8.1. Kết quả đạt được**

Bài báo cáo đã trình bày một cách có hệ thống đề tài edge–cloud computing cho truyền thông đa phương tiện và phân tích ngữ nghĩa dữ liệu hình ảnh lớn. Nội dung đã làm rõ bối cảnh, phát biểu bài toán, mục tiêu, câu hỏi nghiên cứu, nền tảng kỹ thuật, kiến trúc đề xuất, cơ chế offloading, thiết kế thực nghiệm, chỉ số đánh giá và khả năng ứng dụng thực tế.

Điểm trọng tâm của đề tài là chuyển từ cách nhìn “xử lý ảnh bằng một mô hình AI” sang cách nhìn “thiết kế hệ thống xử lý phân tán cho dữ liệu hình ảnh lớn”. Trong hệ thống này, edge giúp giảm độ trễ và băng thông, còn cloud giúp duy trì độ chính xác và cung cấp phân tích tổng hợp. Cơ chế offloading là thành phần quyết định giúp cân bằng giữa hai phía.

### **8.2. Ý nghĩa nghiên cứu và ứng dụng**

Về mặt nghiên cứu, đề tài hệ thống hóa các khái niệm và nghiên cứu liên quan đến edge computing, cloud computing, collaborative inference và phân tích ngữ nghĩa hình ảnh. Về mặt ứng dụng, mô hình đề xuất có thể triển khai trong giám sát video, giao thông thông minh, kho ảnh số, truyền thông số và công nghiệp. Về mặt thực nghiệm, đề tài có thể tạo ra kết quả định lượng thông qua so sánh cloud-only, edge-only và edge–cloud.

### **8.3. Hạn chế**

Do phạm vi báo cáo, nội dung chưa triển khai đầy đủ trên một hệ thống camera thực tế quy mô lớn. Các kết quả trong báo cáo chủ yếu là thiết kế thực nghiệm và phương án đánh giá. Khi triển khai thực tế, cần tiếp tục xử lý các vấn đề như tối ưu mô hình, bảo mật dữ liệu, giám sát hệ thống, quản lý phiên bản mô hình và độ ổn

định mạng.

#### **8.4. Hướng nghiên cứu tiếp theo**

Hướng nghiên cứu tiếp theo là triển khai hệ thống thử nghiệm hoàn chỉnh, chạy trên dataset thật, đo các chỉ số latency, bandwidth, mAP, throughput và resource usage; sau đó mở rộng sang offloading thích ứng, tìm kiếm ngữ nghĩa bằng CLIP, tối ưu mô hình cho edge và federated learning.

## TÀI LIỆU THAM KHẢO

- [1] W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu, “Edge computing: Vision and challenges,” *IEEE Internet of Things Journal*, vol. 3, no. 5, pp. 637–646, 2016.
- [2] F. Bonomi, R. Milito, J. Zhu, and S. Addepalli, “Fog computing and its role in the internet of things,” in *Proceedings of the First Edition of the MCC Workshop on Mobile Cloud Computing*. ACM, 2012, pp. 13–16.
- [3] M. Armbrust, A. Fox, R. Griffith, A. D. Joseph, R. Katz, A. Konwinski, G. Lee, D. Patterson, A. Rabkin, I. Stoica, and M. Zaharia, “A view of cloud computing,” *Communications of the ACM*, vol. 53, no. 4, pp. 50–58, 2010.
- [4] M. Satyanarayanan, “The emergence of edge computing,” *Computer*, vol. 50, no. 1, pp. 30–39, 2017.
- [5] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, “Microsoft COCO: Common objects in context,” in *European Conference on Computer Vision*. Springer, 2014, pp. 740–755.
- [6] Y. Kang, J. Hauswald, C. Gao, A. Rovinski, T. Mudge, J. Mars, and L. Tang, “Neurosurgeon: Collaborative intelligence between the cloud and mobile edge,” in *Proceedings of the Twenty-Second International Conference on Architectural Support for Programming Languages and Operating Systems*. ACM, 2017, pp. 615–629.
- [7] S. Teerapittayanon, B. McDanel, and H. T. Kung, “Distributed deep neural networks over the cloud, the edge and end devices,” in *2017 IEEE 37th International Conference on Distributed Computing Systems*. IEEE, 2017, pp. 328–339.
- [8] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “Imagenet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems*, vol. 25, 2012.

- [9] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778.
- [10] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 779–788.
- [11] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, “Learning transferable visual models from natural language supervision,” in *Proceedings of the 38th International Conference on Machine Learning*, 2021, pp. 8748–8763.
- [12] W.-Q. Ren, Y.-B. Qu, C. Dong, Y.-Q. Jing, H. Sun, Q.-H. Wu, and S. Guo, “A survey on collaborative dnn inference for edge intelligence,” *Machine Intelligence Research*, vol. 20, no. 3, pp. 370–395, 2023.
- [13] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, and H. Adam, “MobileNets: Efficient convolutional neural networks for mobile vision applications,” *arXiv preprint arXiv:1704.04861*, 2017.
- [14] Y. Wang *et al.*, “End-edge-cloud collaborative computing for deep learning: A comprehensive survey,” *IEEE Communications Surveys & Tutorials*, 2024.
- [15] Ultralytics, “YOLOv8: A state-of-the-art real-time object detection model,” Online documentation, 2023, accessed: 2026-05-16. [Online]. Available: <https://docs.ultralytics.com/models/yolov8/>