

**VIỆN HÀN LÂM KHOA HỌC VÀ CÔNG NGHỆ VIỆT NAM
HỌC VIỆN KHOA HỌC VÀ CÔNG NGHỆ**



**BÁO CÁO TIỂU LUẬN KẾT THÚC HỌC
PHẦN THẠC SĨ
TRUYỀN THÔNG ĐA PHƯƠNG TIỆN**

ĐỀ TÀI

**EDGE-CLOUD COMPUTING CHO TRUYỀN
THÔNG ĐA PHƯƠNG TIỆN VÀ PHÂN TÍCH
NGŨ NGHĨA DỮ LIỆU HÌNH ẢNH LỚN**

Học viên thực hiện : Trần Đại Dương

Mã học viên : 25810009

Lớp : ITT2025

Giảng viên : TS. Ngô Hải Anh

Hà Nội, Tháng 5 năm 2026

PHIẾU CHẤM ĐIỂM

Học viên thực hiện:

Họ và tên	Chữ ký	Ghi chú
Trần Đại Dương		

Giảng viên chấm:

Họ và tên	Điểm	Chữ ký
Giảng viên chấm 1:		
Giảng viên chấm 2:		

LỜI CẢM ƠN

Lời đầu tiên, em xin gửi lời cảm ơn chân thành đến thầy giáo **TS. Ngô Hải Anh** đã hướng dẫn, định hướng và hỗ trợ em trong quá trình học tập học phần **Truyền thông đa phương tiện**. Những kiến thức về xử lý dữ liệu đa phương tiện, truyền tải nội dung, hệ thống phân tán và các xu hướng ứng dụng trí tuệ nhân tạo đã giúp em có cơ sở để thực hiện bài tiểu luận với đề tài *“Edge-cloud computing cho truyền thông đa phương tiện và phân tích ngữ nghĩa dữ liệu hình ảnh lớn”*.

Em cũng xin cảm ơn Học viện Khoa học và Công nghệ đã tạo điều kiện học tập, nghiên cứu và tiếp cận các kiến thức mới trong lĩnh vực công nghệ thông tin. Trong quá trình thực hiện, mặc dù đã cố gắng tìm hiểu và hệ thống hóa nội dung, bài tiểu luận khó tránh khỏi thiếu sót. Em kính mong nhận được các ý kiến góp ý của thầy để bài làm được hoàn thiện hơn.

Em xin chân thành cảm ơn!

Hà Nội, ngày 20 tháng 5 năm 2026

HỌC VIÊN THỰC HIỆN

Trần Đại Dương

Mục lục

DANH MỤC CÁC KÝ HIỆU, TỪ VIẾT TẮT	8
DANH MỤC HÌNH ẢNH	13
DANH MỤC BẢNG	14
LỜI MỞ ĐẦU	15
CHƯƠNG 1: TỔNG QUAN VÀ XÁC ĐỊNH BÀI TOÁN NGHIÊN CỨU	16
1.1 Bối cảnh hình thành đề tài	16
1.2 Phát biểu bài toán nghiên cứu	16
1.3 Đối tượng, phạm vi và giả định nghiên cứu	17
1.3.1 Đối tượng nghiên cứu	17
1.3.2 Phạm vi nghiên cứu	17
1.3.3 Giả định nghiên cứu	18
1.4 Mục tiêu nghiên cứu	19
1.4.1 Mục tiêu tổng quát	19
1.4.2 Mục tiêu cụ thể	19
1.5 Câu hỏi nghiên cứu và giả thuyết	20
1.6 Đóng góp dự kiến của đề tài	21
1.7 Kết luận chương 1	21
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN....	22
2.1 Cloud computing trong xử lý đa phương tiện	22
2.2 Edge computing và fog computing	22
2.3 Collaborative inference giữa edge và cloud	23
2.4 Phân tích ngữ nghĩa dữ liệu hình ảnh	23
2.5 Các mô hình triển khai: cloud-only, edge-only và edge-cloud	24
2.6 Tổng quan nghiên cứu liên quan	25
2.7 Kết luận chương 2	25

CHƯƠNG 3: MÔ HÌNH NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG

ĐỀ XUẤT	26
3.1 Quan điểm thiết kế mô hình	26
3.2 Yêu cầu chức năng và phi chức năng	26
3.2.1 Yêu cầu chức năng	26
3.2.2 Yêu cầu phi chức năng	27
3.3 Kiến trúc tổng thể	27
3.4 Luồng xử lý dữ liệu	28
3.5 Mô hình dữ liệu ngữ nghĩa	29
3.6 Cơ chế offloading đề xuất	30
3.7 Thuật toán xử lý đề xuất	32
3.8 Kết luận chương 3	32

CHƯƠNG 4: THIẾT KẾ THỰC NGHIỆM VÀ PHƯƠNG PHÁP ĐÁNH

GIÁ	33
4.1 Mục tiêu thực nghiệm	33
4.2 Môi trường thực nghiệm đề xuất	33
4.3 Thiết lập tham số cho prototype	34
4.4 Dữ liệu thực nghiệm	35
4.5 Các mô hình đối chứng	36
4.6 Kịch bản thực nghiệm	36
4.6.1 Kịch bản 1: So sánh độ trễ	36
4.6.2 Kịch bản 2: So sánh băng thông	37
4.6.3 Kịch bản 3: So sánh độ chính xác	37
4.6.4 Kịch bản 4: Thay đổi ngưỡng confidence	37
4.6.5 Kịch bản 5: Giả lập mạng yếu	38
4.7 Bộ chỉ số đánh giá	38
4.8 Thiết kế dashboard và log thực nghiệm	38
4.9 Quy trình thực nghiệm tổng quát	40

4.10	Kết luận chương 4	40
------	-------------------------	----

CHƯƠNG 5: KHUNG ĐÁNH GIÁ, KẾT QUẢ PROTOTYPE VÀ PHÂN TÍCH KHẢ NĂNG ỨNG DỤNG MÔ HÌNH

5.1	Mục tiêu đánh giá	41
5.2	Nguyên tắc quyết định offloading trong prototype	41
5.3	Kết quả thử nghiệm sơ bộ trên prototype	42
5.4	Phân tích kết quả prototype	43
5.4.1	Độ trễ xử lý	43
5.4.2	Băng thông truyền tải	44
5.4.3	Throughput	44
5.4.4	Confidence và số lượng đối tượng	45
5.4.5	Tài nguyên tính toán	45
5.4.6	Tỷ lệ offload	46
5.5	Khung so sánh định tính giữa các mô hình triển khai	46
5.6	Nhận xét về khả năng ứng dụng từ kết quả prototype	46
5.7	Hạn chế của nghiên cứu	47
5.8	Kết luận chương 5	48

CHƯƠNG 6: KHẢ NĂNG TRIỂN KHAI VÀ ỨNG DỤNG THỰC TẾ ..

6.1	Ứng dụng trong giám sát video thông minh	49
6.2	Ứng dụng trong giao thông thông minh	49
6.3	Ứng dụng trong kho ảnh số và truyền thông số	49
6.4	Ứng dụng trong công nghiệp và kho bãi	50
6.5	Kiến trúc ứng dụng mẫu	50
6.6	Lộ trình triển khai sản phẩm thử nghiệm	50
6.7	Kết luận chương 6	51

CHƯƠNG 7: THÁCH THỨC, BẢO MẬT VÀ HƯỚNG PHÁT TRIỂN ..

7.1	Thách thức về cân bằng độ trễ và độ chính xác	52
-----	---	----

7.2	Thách thức về quản lý mô hình.....	52
7.3	Bảo mật và riêng tư dữ liệu	52
7.4	Hướng phát triển nghiên cứu	53
7.5	Kết luận chương 7.....	53
CHƯƠNG 8: KẾT LUẬN.....		54
8.1	Kết quả đạt được	54
8.2	Ý nghĩa nghiên cứu và ứng dụng	54
8.3	Hạn chế.....	54
8.4	Hướng nghiên cứu tiếp theo.....	55
TÀI LIỆU THAM KHẢO		56

DANH MỤC CÁC KÝ HIỆU, TỪ VIẾT TẮT

Ký hiệu / Viết tắt Ý nghĩa

AI	Artificial Intelligence – Trí tuệ nhân tạo.
API	Application Programming Interface – Giao diện lập trình ứng dụng.
Bandwidth	Băng thông truyền tải dữ liệu giữa edge và cloud.
CLIP	Contrastive Language–Image Pre-training – Mô hình thị giác–ngôn ngữ hỗ trợ biểu diễn và tìm kiếm ngữ nghĩa ảnh.
Cloud	Lớp xử lý đám mây, có tài nguyên tính toán và lưu trữ lớn hơn edge.
Cloud-only	Mô hình triển khai trong đó dữ liệu được gửi lên cloud để xử lý gần như toàn bộ.
CNN	Convolutional Neural Network – Mạng nơ-ron tích chập, thường dùng trong xử lý ảnh.
COCO	Common Objects in Context – Bộ dữ liệu ảnh phổ biến cho bài toán phát hiện đối tượng và phân đoạn ảnh.
CPU	Central Processing Unit – Bộ xử lý trung tâm.
CUDA	Compute Unified Device Architecture – Nền tảng tính toán song song trên GPU của NVIDIA.
DNN	Deep Neural Network – Mạng nơ-ron sâu.

Ký hiệu / Viết tắt Ý nghĩa

Docker	Nền tảng container hóa, hỗ trợ triển khai các thành phần edge và cloud trong môi trường độc lập.
Edge	Lớp xử lý gần nguồn phát sinh dữ liệu, ví dụ camera gateway, thiết bị IoT, máy chủ biên hoặc mini PC.
Edge-only	Mô hình triển khai trong đó toàn bộ dữ liệu được xử lý tại edge, không gửi lên cloud trong quá trình suy luận.
Edge–cloud	Mô hình phối hợp giữa edge và cloud, trong đó edge xử lý sơ bộ hoặc xử lý nhanh, cloud xử lý các trường hợp phức tạp hơn.
Embedding	Vector đặc trưng biểu diễn nội dung ảnh/video, phục vụ tìm kiếm tương đồng hoặc tìm kiếm ngữ nghĩa.
FPS	Frames Per Second – Số khung hình xử lý trong một giây.
GPU	Graphics Processing Unit – Bộ xử lý đồ họa, thường dùng để tăng tốc các mô hình học sâu.
IoT	Internet of Things – Internet vạn vật.
Latency	Độ trễ xử lý, tính từ thời điểm hệ thống nhận dữ liệu đến khi có kết quả phân tích.
mAP	mean Average Precision – Độ chính xác trung bình, thường dùng để đánh giá mô hình phát hiện đối tượng.
Metadata	Siêu dữ liệu mô tả nội dung ảnh/video, ví dụ nhãn đối tượng, bounding box, confidence, thời gian xử lý và vị trí xử lý.

Ký hiệu / Viết tắt Ý nghĩa

MobileNet	Nhóm mô hình học sâu nhẹ, phù hợp với thiết bị có tài nguyên hạn chế.
ONNX	Open Neural Network Exchange – Định dạng trung gian để trao đổi và triển khai mô hình học sâu trên nhiều nền tảng.
OpenCV	Open Source Computer Vision Library – Thư viện mã nguồn mở phục vụ xử lý ảnh và video.
Offloading	Quá trình quyết định gửi dữ liệu hoặc tác vụ từ edge lên cloud để xử lý.
Offload ratio	Tỷ lệ ảnh hoặc khung hình được gửi lên cloud trên tổng số dữ liệu đầu vào.
P95 Latency	Giá trị độ trễ tại phân vị 95%, dùng để đánh giá độ trễ trong các trường hợp gần mức cao nhất.
Precision	Tỷ lệ kết quả dự đoán đúng trên tổng số kết quả được mô hình dự đoán.
Prototype	Hệ thống thử nghiệm hoặc bản demo dùng để minh họa cơ chế hoạt động của mô hình đề xuất.
QoS	Quality of Service – Chất lượng dịch vụ.
RAM	Random Access Memory – Bộ nhớ truy cập ngẫu nhiên.
Recall	Tỷ lệ đối tượng thực tế được mô hình phát hiện đúng.

Ký hiệu / Viết tắt Ý nghĩa

ROI	Region of Interest – Vùng quan tâm trong ảnh hoặc khung hình video.
RTSP	Real Time Streaming Protocol – Giao thức truyền video thời gian thực.
SLA	Service Level Agreement – Thỏa thuận mức dịch vụ.
Throughput	Số ảnh hoặc khung hình hệ thống xử lý được trong một đơn vị thời gian.
YOLO	You Only Look Once – Nhóm mô hình phát hiện đối tượng thời gian thực.
$c_{\max}(x)$	Confidence lớn nhất trong các đối tượng phát hiện được từ ảnh hoặc khung hình x .
$c_{\text{avg}}(x)$	Confidence trung bình của các đối tượng phát hiện được từ ảnh hoặc khung hình x .
$N_{\text{obj}}(x)$	Số lượng đối tượng phát hiện được trong ảnh hoặc khung hình x .
U_{edge}	Mức sử dụng tài nguyên tại edge, có thể tính theo CPU, RAM hoặc GPU.
$\tau_{\max}$	Ngưỡng confidence lớn nhất dùng trong quyết định offloading.
τ_{avg}	Ngưỡng confidence trung bình dùng trong quyết định offloading.

Ký hiệu / Viết tắt Ý nghĩa

τ_n	Ngưỡng số lượng đối tượng tối đa cho phép xử lý tại edge.
τ_u	Ngưỡng tải tài nguyên tối đa tại edge.
$D(x)$	Hàm quyết định nơi xử lý dữ liệu x , gồm xử lý tại edge hoặc offload lên cloud.
T_{total}	Tổng độ trễ xử lý của một ảnh hoặc khung hình.
T_{capture}	Thời gian thu nhận ảnh hoặc khung hình từ nguồn dữ liệu.
$T_{\text{preprocess}}$	Thời gian tiền xử lý dữ liệu tại edge.
T_{upload}	Thời gian upload dữ liệu từ edge lên cloud.
T_{download}	Thời gian nhận kết quả từ cloud về edge hoặc ứng dụng.
$T_{\text{postprocess}}$	Thời gian hậu xử lý kết quả sau suy luận.
S_{raw}	Dung lượng dữ liệu thô nếu gửi toàn bộ lên cloud.
S_{uploaded}	Dung lượng dữ liệu thực tế được gửi từ edge lên cloud.
η_{bw}	Tỷ lệ tiết kiệm băng thông so với mô hình cloud-only.

DANH MỤC HÌNH ẢNH

1.1	Mô tả bài toán nghiên cứu của đề tài	17
3.1	Kiến trúc edge–cloud đề xuất cho phân tích ngữ nghĩa dữ liệu hình ảnh lớn	28
3.2	Quy trình xử lý và quyết định offloading	29
4.1	Giao diện thiết lập tham số offloading trong hệ thống prototype	35
4.2	Quy trình thực nghiệm đề xuất.....	40
6.1	Kiến trúc ứng dụng mẫu cho hệ thống phân tích ảnh/video edge–cloud	50

DANH MỤC CÁC BẢNG

1.1	Câu hỏi nghiên cứu của đề tài	20
2.1	So sánh ba mô hình triển khai xử lý ảnh/video	24
3.1	Các tham số quyết định offloading trong hệ thống demo	31
3.2	Quy tắc quyết định offloading trong mô hình edge–cloud	31
4.1	Môi trường thực nghiệm đề xuất	34
4.2	Nhóm chỉ số đánh giá hiệu năng hệ thống	38
4.3	Nhóm chỉ số đánh giá chất lượng phân tích và chi phí	39
5.1	Các tham số quyết định offloading trong hệ thống prototype	42
5.2	Kết quả so sánh ba kịch bản xử lý trên hệ thống prototype	43
5.3	Khung so sánh định tính giữa các mô hình triển khai	47

LỜI MỞ ĐẦU

Trong bối cảnh chuyển đổi số, dữ liệu đa phương tiện, đặc biệt là hình ảnh và video, được tạo ra với tốc độ ngày càng lớn từ camera giám sát, thiết bị di động, cảm biến đô thị thông minh, nền tảng mạng xã hội, hệ thống giao thông và các ứng dụng công nghiệp. Khác với dữ liệu văn bản truyền thống, dữ liệu hình ảnh lớn có dung lượng cao, cấu trúc phức tạp và thường yêu cầu xử lý theo thời gian gần thực. Để khai thác giá trị của dữ liệu này, hệ thống không chỉ cần lưu trữ hoặc truyền tải, mà còn phải hiểu được nội dung bên trong ảnh/video như đối tượng, cảnh, hành vi, quan hệ không gian và các sự kiện đáng chú ý. Các nghiên cứu về edge computing và fog computing cho thấy việc đưa xử lý đến gần nguồn dữ liệu là hướng phù hợp với các ứng dụng cần độ trễ thấp, nhận biết vị trí và xử lý dòng dữ liệu liên tục [1, 2].

Cloud computing cung cấp năng lực tính toán mạnh, khả năng mở rộng linh hoạt và phù hợp với các mô hình học sâu quy mô lớn [3]. Tuy nhiên, việc truyền toàn bộ dữ liệu hình ảnh/video lên cloud có thể gây tăng độ trễ, tiêu tốn băng thông, phát sinh chi phí và làm nảy sinh yêu cầu bảo mật dữ liệu. Edge computing đưa một phần năng lực xử lý về gần nguồn dữ liệu, giúp giảm tải mạng và phản hồi nhanh hơn [1, 4]. Mô hình edge–cloud computing kết hợp hai hướng tiếp cận này, trong đó edge đảm nhiệm thu thập, tiền xử lý, lọc dữ liệu, suy luận nhanh; cloud đảm nhiệm xử lý sâu, huấn luyện/cập nhật mô hình, lưu trữ và phân tích tổng hợp.

Bài tiểu luận tập trung nghiên cứu mô hình edge–cloud computing cho truyền thông đa phương tiện và phân tích ngữ nghĩa dữ liệu hình ảnh lớn. Trọng tâm của bài là xây dựng một kiến trúc logic có thể triển khai thực nghiệm, đề xuất quy trình xử lý ảnh/video từ tầng edge đến cloud, phân tích các kỹ thuật chính, đồng thời đưa ra tiêu chí đánh giá hiệu quả hệ thống.

CHƯƠNG 1: TỔNG QUAN VÀ XÁC ĐỊNH BÀI TOÁN NGHIÊN CỨU

1.1. Bối cảnh hình thành đề tài

Trong môi trường truyền thông đa phương tiện hiện đại, dữ liệu hình ảnh và video không còn chỉ được lưu trữ để xem lại, mà trở thành nguồn dữ liệu đầu vào cho các hệ thống phân tích thông minh. Camera giám sát, thiết bị di động, cảm biến IoT, nền tảng mạng xã hội, hệ thống giao thông thông minh và các kho ảnh số tạo ra lượng dữ liệu rất lớn theo thời gian thực. Để khai thác giá trị của dữ liệu này, hệ thống cần chuyển đổi dữ liệu ảnh/video thô thành thông tin có ý nghĩa như đối tượng xuất hiện, bối cảnh, hành vi, sự kiện, mức độ bất thường, từ khóa tìm kiếm và metadata phục vụ báo cáo.


Mô hình xử lý tập trung trên cloud có ưu điểm về năng lực tính toán, khả năng mở rộng và phù hợp với các mô hình học sâu lớn [3]. Tuy nhiên, khi dữ liệu đầu vào là ảnh độ phân giải cao hoặc video liên tục, việc truyền toàn bộ dữ liệu lên cloud có thể tạo ra độ trễ lớn, tiêu tốn băng thông, tăng chi phí lưu trữ và làm phát sinh rủi ro riêng tư dữ liệu. Edge computing đưa một phần xử lý về gần nguồn dữ liệu, giúp giảm độ trễ và giảm lượng dữ liệu cần truyền [1, 4]. Tuy vậy, thiết bị edge thường hạn chế về CPU, GPU, RAM, năng lượng và dung lượng lưu trữ. Vì vậy, cách tiếp cận hợp lý là phối hợp giữa edge và cloud: edge xử lý nhanh các tác vụ nhẹ và dữ liệu rõ ràng, còn cloud xử lý các trường hợp khó, huấn luyện mô hình và phân tích tổng hợp.

1.2. Phát biểu bài toán nghiên cứu

Bài toán trung tâm của đề tài được phát biểu như sau: *Làm thế nào để thiết kế một mô hình edge–cloud computing cho phép phân tích ngữ nghĩa dữ liệu hình ảnh/video lớn trong truyền thông đa phương tiện, đồng thời cân bằng được ba yếu tố quan*

trọng: độ trễ xử lý, băng thông truyền tải và độ chính xác phân tích?

Cụ thể, hệ thống đầu vào gồm nhiều nguồn ảnh/video như camera, kho ảnh, thiết bị di động hoặc luồng dữ liệu từ ứng dụng. Mỗi ảnh hoặc khung hình video cần được xử lý để tạo ra kết quả ngữ nghĩa gồm nhãn đối tượng, vùng chứa đối tượng, độ tin cậy, metadata, embedding phục vụ tìm kiếm và cảnh báo sự kiện. Nếu toàn bộ dữ liệu được gửi lên cloud, độ chính xác có thể cao nhưng độ trễ và băng thông lớn. Nếu toàn bộ dữ liệu được xử lý tại edge, độ trễ thấp nhưng độ chính xác có thể giảm do mô hình nhẹ. Vì vậy, bài toán không chỉ là lựa chọn mô hình AI, mà là bài toán phân phối tác vụ xử lý giữa edge và cloud.



Hình 1.1: Mô tả bài toán nghiên cứu của đề tài

1.3. Đối tượng, phạm vi và giả định nghiên cứu

1.3.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là mô hình xử lý phân tán giữa edge và cloud cho dữ liệu ảnh/video trong truyền thông đa phương tiện. Trọng tâm không phải là xây dựng một mô hình thị giác máy tính mới hoàn toàn, mà là nghiên cứu cách tổ chức hệ thống, cách phân chia xử lý, cách quyết định offloading và cách đánh giá hiệu quả của mô hình phối hợp.

1.3.2. Phạm vi nghiên cứu

Phạm vi của đề tài gồm các nội dung sau:

- Phân tích dữ liệu đầu vào là ảnh tĩnh, khung hình video hoặc luồng video từ camera.
- Tập trung vào các tác vụ phát hiện đối tượng, tạo metadata ngữ nghĩa, trích xuất embedding và tìm kiếm ngữ nghĩa.
- Thiết kế kiến trúc edge–cloud gồm nguồn dữ liệu, edge node, cloud server, kho metadata và dashboard/API ứng dụng.
- Đề xuất cơ chế offloading dựa trên độ tin cậy của mô hình, độ phức tạp cảnh, tải edge và trạng thái mạng.
- Đưa ra phương án thực nghiệm có thể triển khai bằng Docker, Python, OpenCV, mô hình YOLO nhẹ ở edge và mô hình mạnh hơn ở cloud.

Đề tài không đi sâu vào huấn luyện từ đầu một mô hình học sâu quy mô lớn, không triển khai trên hệ thống camera thật quy mô thành phố và không xử lý đầy đủ tất cả dạng dữ liệu đa phương tiện như âm thanh hay văn bản. Bài báo PMNet được xem là tài liệu tham khảo tiêu biểu cho hướng xử lý ảnh lớn trên nền edge–cloud, nhưng phạm vi báo cáo không tái hiện bài toán phân đoạn vùng nước của PMNet. Thay vào đó, báo cáo lựa chọn hướng tổng quát hơn: thiết kế mô hình edge–cloud cho phân tích ngữ nghĩa ảnh/video, sử dụng phát hiện đối tượng và metadata extraction làm tác vụ minh họa. Tuy nhiên, mô hình đề xuất có thể mở rộng sang semantic segmentation, tìm kiếm ảnh và các dạng dữ liệu đa phương tiện khác trong hướng phát triển tiếp theo.

1.3.3. Giả định nghiên cứu

Để mô hình nghiên cứu có thể thực nghiệm trong phạm vi học phần, đề tài đặt ra một số giả định:

- Edge node có tài nguyên hạn chế hơn cloud, có thể là máy tính mini, Raspberry Pi, Jetson Nano hoặc một máy ảo/container được giới hạn CPU/RAM.

- Cloud node có năng lực tính toán mạnh hơn, có thể chạy mô hình lớn hơn hoặc xử lý batch nhiều yêu cầu.
- Mạng giữa edge và cloud có độ trễ và băng thông có thể đo được, có thể giả lập bằng giới hạn tốc độ mạng.
- Dữ liệu thử nghiệm có nhãn để đánh giá độ chính xác, hoặc có thể dùng bộ dữ liệu chuẩn như COCO [5].

1.4. Mục tiêu nghiên cứu

1.4.1. Mục tiêu tổng quát

Mục tiêu tổng quát của đề tài là xây dựng và đánh giá một mô hình edge–cloud computing cho phân tích ngữ nghĩa dữ liệu hình ảnh lớn trong truyền thông đa phương tiện, trong đó edge xử lý nhanh và giảm dữ liệu truyền tải, còn cloud đảm nhiệm phân tích sâu và quản lý tập trung.

1.4.2. Mục tiêu cụ thể

Các mục tiêu cụ thể gồm:

1. Hệ thống hóa cơ sở lý thuyết về cloud computing, edge computing, fog computing và collaborative inference.
2. Làm rõ đặc điểm của dữ liệu hình ảnh/video lớn và yêu cầu phân tích ngữ nghĩa trong truyền thông đa phương tiện.
3. Đề xuất kiến trúc hệ thống edge–cloud có thể triển khai thử nghiệm.
4. Xây dựng cơ chế quyết định offloading dựa trên ngưỡng tin cậy, tải tài nguyên và điều kiện mạng.
5. Thiết kế bộ kịch bản thực nghiệm so sánh cloud-only, edge-only và edge–cloud.

6. Đề xuất các chỉ số đánh giá gồm latency, bandwidth, accuracy, CPU/RAM/GPU, throughput và chi phí vận hành.
7. Phân tích khả năng ứng dụng trong giám sát video, giao thông thông minh, kho ảnh số, truyền thông số và tìm kiếm ngữ nghĩa.

1.5. Câu hỏi nghiên cứu và giả thuyết

Mã	Nội dung câu hỏi nghiên cứu
RQ1	Mô hình cloud-only, edge-only và edge–cloud khác nhau như thế nào về độ trễ, băng thông, độ chính xác và tài nguyên hệ thống?
RQ2	Edge có thể giảm lượng dữ liệu gửi lên cloud bằng các kỹ thuật tiền xử lý, lọc khung hình, cắt vùng quan tâm và gửi metadata đến mức nào?
RQ3	Ngưỡng confidence và tài tài nguyên edge ảnh hưởng như thế nào đến quyết định offloading?
RQ4	Mô hình edge–cloud có thể đạt độ chính xác gần cloud-only nhưng giảm độ trễ và băng thông so với cloud-only hay không?
RQ5	Kiến trúc đề xuất có thể ứng dụng trong các hệ thống truyền thông đa phương tiện thực tế như giám sát video, giao thông thông minh và tìm kiếm ảnh/video hay không?

Bảng 1.1: Câu hỏi nghiên cứu của đề tài

Từ các câu hỏi trên, đề tài đặt ra các giả thuyết nghiên cứu:

- **H1:** Edge–cloud có thể giảm băng thông truyền tải so với cloud-only nhờ chỉ gửi dữ liệu cần phân tích sâu.
- **H2:** Edge–cloud có thể giảm độ trễ trung bình so với cloud-only trong các trường hợp ảnh/video đơn giản được xử lý tại edge.

- **H3:** Edge–cloud có thể đạt độ chính xác cao hơn edge-only nhờ cloud xử lý lại các trường hợp có độ tin cậy thấp.
- **H4:** Cơ chế offloading thích hợp giúp hệ thống cân bằng tốt hơn giữa hiệu năng và chất lượng phân tích.

1.6. Đóng góp dự kiến của đề tài

Đề tài có ba nhóm đóng góp chính. Thứ nhất, về mặt nghiên cứu, đề tài hệ thống hóa bài toán phân tích ngữ nghĩa hình ảnh lớn trong bối cảnh edge–cloud computing, làm rõ các biến số cần đánh giá và các ràng buộc của hệ thống. Thứ hai, về mặt kỹ thuật, đề tài đề xuất kiến trúc xử lý phân tầng gồm edge node, cloud node, kho metadata và dashboard/API, kèm theo cơ chế offloading có thể triển khai. Thứ ba, về mặt thực nghiệm, đề tài xây dựng phương án đánh giá định lượng để so sánh ba mô hình cloud-only, edge-only và edge–cloud theo nhiều chỉ số.

1.7. Kết luận chương 1

Chương 1 đã làm rõ bối cảnh, phát biểu bài toán, phạm vi, mục tiêu, câu hỏi nghiên cứu, giả thuyết và đóng góp dự kiến của đề tài. Điểm trọng tâm là bài toán không chỉ nằm ở mô hình AI nhận dạng ảnh, mà nằm ở thiết kế hệ thống xử lý phân tán sao cho dữ liệu được phân tích đúng nơi, đúng mức và đúng thời điểm. Đây là cơ sở để chương tiếp theo trình bày các nền tảng kỹ thuật phục vụ xây dựng mô hình.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN

2.1. Cloud computing trong xử lý đa phương tiện

Cloud computing cung cấp tài nguyên tính toán và lưu trữ thông qua các trung tâm dữ liệu lớn. Trong các bài toán xử lý ảnh/video, cloud thường được dùng để lưu trữ dữ liệu lớn, huấn luyện mô hình học sâu, chạy mô hình nhận dạng phức tạp và cung cấp API phân tích nội dung cho nhiều người dùng [3]. Ưu điểm của cloud là năng lực tính toán cao, khả năng mở rộng tốt và dễ quản trị tập trung. Tuy nhiên, cloud-only gặp hạn chế khi dữ liệu phát sinh ở xa trung tâm xử lý hoặc khi ứng dụng yêu cầu phản hồi nhanh.

Với dữ liệu video, chi phí truyền tải là vấn đề đáng kể. Nếu mỗi camera liên tục truyền luồng video độ phân giải cao lên cloud, hệ thống mạng sẽ bị tải lớn, trong khi nhiều khung hình có thể không chứa thông tin mới. Ngoài ra, dữ liệu hình ảnh có thể chứa thông tin nhạy cảm như khuôn mặt, biển số xe hoặc không gian riêng tư, làm phát sinh yêu cầu kiểm soát dữ liệu trước khi đưa lên cloud.

2.2. Edge computing và fog computing

Edge computing là mô hình đưa tính toán đến gần nguồn phát sinh dữ liệu. Theo Shi và cộng sự, edge computing hướng đến xử lý dữ liệu ở biên mạng nhằm giảm độ trễ, giảm tải mạng và hỗ trợ các ứng dụng IoT [1]. Satyanarayanan cũng nhấn mạnh edge computing là hướng tiếp cận quan trọng khi các ứng dụng cần độ trễ thấp và nhận biết ngữ cảnh [4]. Fog computing mở rộng ý tưởng này bằng cách bổ sung tầng trung gian giữa thiết bị đầu cuối và cloud, giúp xử lý, lưu trữ và điều phối dịch vụ ở gần người dùng hơn [2].

Trong hệ thống đa phương tiện, edge có thể thực hiện các tác vụ như giải mã video,

trích xuất khung hình, phát hiện chuyển động, giảm kích thước ảnh, nhận dạng đối tượng bằng mô hình nhẹ và gửi kết quả ngữ nghĩa lên cloud. Điều này đặc biệt phù hợp với các bài toán giám sát, giao thông, sản xuất thông minh và phân tích nội dung thời gian thực.

2.3. Collaborative inference giữa edge và cloud

Collaborative inference là hướng nghiên cứu phân chia quá trình suy luận của mô hình học sâu giữa thiết bị biên và cloud. Thay vì chạy toàn bộ mô hình ở một nơi, hệ thống có thể chạy một phần ở edge và một phần ở cloud, hoặc chạy mô hình nhẹ tại edge trước rồi chỉ gửi trường hợp khó lên cloud. Neurosurgeon là một trong những nghiên cứu tiêu biểu về phối hợp suy luận giữa mobile edge và cloud, trong đó vị trí phân tách mô hình được chọn theo độ trễ và tài nguyên [6]. Distributed Deep Neural Networks cũng cho thấy việc phân bố mạng nơ-ron trên end device, edge và cloud là hướng phù hợp cho các hệ thống phân tán [7].

Trong phạm vi đề tài, collaborative inference được áp dụng theo cách dễ triển khai hơn: edge chạy mô hình nhẹ để suy luận ban đầu; nếu confidence cao, kết quả được chấp nhận; nếu confidence thấp hoặc cảnh phức tạp, dữ liệu được gửi lên cloud để xử lý bằng mô hình mạnh hơn. Cách này phù hợp với điều kiện thực nghiệm của một báo cáo học phần vì không yêu cầu can thiệp sâu vào cấu trúc bên trong của mô hình DNN.

2.4. Phân tích ngữ nghĩa dữ liệu hình ảnh

Phân tích ngữ nghĩa dữ liệu hình ảnh là quá trình chuyển đổi dữ liệu ảnh/video thô thành thông tin có ý nghĩa. Các cấp độ phân tích thường gồm:

- **Phát hiện đối tượng:** xác định đối tượng và vị trí trong ảnh.
- **Phân loại ảnh:** gán ảnh vào một hoặc nhiều nhóm nội dung.
- **Phân đoạn ảnh:** xác định vùng pixel tương ứng với từng lớp đối tượng.

- **Trích xuất embedding:** biểu diễn ảnh bằng vector đặc trưng để phục vụ tìm kiếm.
- **Tìm kiếm ngữ nghĩa:** tìm ảnh/video theo ý nghĩa nội dung thay vì chỉ theo tên tệp.
- **Phát hiện sự kiện:** xác định hành vi, tình huống hoặc bất thường trong ảnh/video.

Các mô hình học sâu như CNN, ResNet và YOLO đã tạo nền tảng cho xử lý ảnh hiện đại [8–10]. Các mô hình thị giác-ngôn ngữ như CLIP mở rộng khả năng liên kết ảnh với văn bản, hỗ trợ tìm kiếm ngữ nghĩa và phân loại zero-shot [11]. Trong hệ thống đề xuất, YOLO có thể dùng cho phát hiện đối tượng, còn embedding có thể dùng cho tìm kiếm ảnh tương đồng.

2.5. Các mô hình triển khai: cloud-only, edge-only và edge–cloud

Để đánh giá mô hình đề xuất, cần làm rõ ba mô hình triển khai đối chứng: cloud-only, edge-only và edge–cloud. Mỗi mô hình có đặc điểm khác nhau về vị trí xử lý, độ trễ, băng thông, độ chính xác và yêu cầu tài nguyên.

Tiêu chí	Cloud-only	Edge-only	Edge–cloud
Vị trí xử lý	Cloud xử lý gần như toàn bộ dữ liệu	Edge xử lý toàn bộ dữ liệu	Edge xử lý sơ bộ, cloud xử lý trường hợp khó
Độ trễ	Phụ thuộc truyền dữ liệu lên cloud	Thấp nếu mô hình nhẹ và edge đủ tài nguyên	Linh hoạt, có thể giảm độ trễ trung bình
Băng thông	Cao do gửi dữ liệu thô lên cloud	Thấp hoặc gần như bằng 0 khi suy luận	Trung bình đến thấp, phụ thuộc tỷ lệ offload
Độ chính xác	Cao nếu dùng mô hình lớn	Có thể thấp hơn do dùng mô hình nhẹ	Gần cloud-only nếu cơ chế offloading tốt
Tài nguyên edge	Thấp	Cao hơn	Trung bình, phụ thuộc mức xử lý tại edge
Tài nguyên cloud	Cao	Thấp	Phụ thuộc tỷ lệ dữ liệu được offload
Phù hợp	Phân tích batch, lưu trữ tập trung, không yêu cầu thời gian thực	Tác vụ đơn giản, mạng yếu, cần phản hồi nhanh	Ứng dụng gần thời gian thực cần cân bằng độ trễ, băng thông và độ chính xác

Bảng 2.1: So sánh ba mô hình triển khai xử lý ảnh/video

2.6. Tổng quan nghiên cứu liên quan

Các nghiên cứu liên quan có thể chia thành bốn nhóm. Nhóm thứ nhất nghiên cứu nền tảng edge/fog computing, nhấn mạnh việc đưa xử lý đến gần nguồn dữ liệu để giảm độ trễ và hỗ trợ IoT [1,2,4]. Nhóm thứ hai nghiên cứu collaborative inference, trong đó tác vụ suy luận được phân phối giữa thiết bị, edge và cloud [6,7,12]. Nhóm thứ ba nghiên cứu mô hình thị giác máy tính như YOLO, ResNet, MobileNet và CLIP phục vụ phát hiện đối tượng, phân loại ảnh và tìm kiếm ngữ nghĩa [9–11, 13]. Nhóm thứ tư nghiên cứu các hệ thống end–edge–cloud quy mô lớn cho học sâu, nhấn mạnh việc đánh giá đồng thời latency, accuracy, communication cost và scalability [14].

Khoảng trống nghiên cứu trong phạm vi đề tài là cần một mô hình thực nghiệm rõ ràng, vừa đủ đơn giản để triển khai trong điều kiện học phần, vừa đủ thể hiện bản chất của edge–cloud: có nguồn dữ liệu, edge node, cloud node, cơ chế offloading, bộ chỉ số đánh giá, dashboard minh họa và kịch bản ứng dụng. Vì vậy, chương 3 sẽ đề xuất mô hình nghiên cứu cụ thể có thể triển khai bằng các công cụ phổ biến.

2.7. Kết luận chương 2

Chương 2 đã trình bày các nền tảng kỹ thuật liên quan đến cloud computing, edge computing, fog computing, collaborative inference và phân tích ngữ nghĩa dữ liệu hình ảnh. Các nghiên cứu liên quan cho thấy edge–cloud không chỉ là xu hướng hạ tầng, mà còn là phương pháp thiết kế hệ thống phù hợp cho các bài toán đa phương tiện yêu cầu độ trễ thấp, tiết kiệm băng thông và duy trì độ chính xác. Đây là cơ sở để xây dựng kiến trúc đề xuất ở chương tiếp theo.

CHƯƠNG 3: MÔ HÌNH NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG ĐỀ XUẤT

3.1. Quan điểm thiết kế mô hình

Mô hình đề xuất được thiết kế theo nguyên tắc xử lý phân tầng. Dữ liệu không được gửi toàn bộ lên cloud ngay từ đầu, mà được đánh giá tại edge để xác định giá trị thông tin và mức độ cần thiết của phân tích sâu. Edge đóng vai trò là lớp lọc thông minh, trong khi cloud đóng vai trò là lớp xử lý nâng cao và quản lý tập trung. Quan điểm này phù hợp với các nghiên cứu về edge intelligence và collaborative DNN inference [12, 14].

Mục tiêu của thiết kế không phải loại bỏ cloud, mà giảm sự phụ thuộc vào cloud trong các trường hợp không cần thiết. Đồng thời, mô hình cũng không ép edge xử lý mọi thứ, vì điều này có thể làm giảm độ chính xác và gây quá tải thiết bị. Hệ thống cần một bộ quyết định offloading để xác định dữ liệu nào xử lý tại edge, dữ liệu nào gửi cloud và dữ liệu nào chỉ lưu metadata.

3.2. Yêu cầu chức năng và phi chức năng

3.2.1. Yêu cầu chức năng

Hệ thống cần đáp ứng các chức năng sau:

1. Thu thập ảnh/video từ camera, tệp ảnh hoặc dataset.
2. Tiền xử lý ảnh/video tại edge: resize, normalize, sampling, nén, cắt vùng quan tâm.
3. Chạy mô hình phát hiện đối tượng nhẹ tại edge.
4. Tính confidence, số lượng đối tượng, độ phức tạp cảnh và tải tài nguyên.


5. Quyết định xử lý tại edge hoặc offload lên cloud.
6. Cloud chạy mô hình mạnh hơn, tạo metadata và embedding.
7. Lưu kết quả vào cơ sở dữ liệu metadata và kho vector.
8. Cung cấp dashboard giám sát, API tìm kiếm và báo cáo thống kê.

3.2.2. *Yêu cầu phi chức năng*

- **Hiệu năng:** độ trễ xử lý phải đủ thấp cho ứng dụng gần thời gian thực.
- **Mở rộng:** có thể bổ sung nhiều edge node hoặc nhiều nguồn dữ liệu.
- **Độ tin cậy:** edge cần xử lý tạm thời khi mất kết nối cloud.
- **Bảo mật:** dữ liệu truyền giữa edge và cloud cần xác thực và mã hóa.
- **Quan sát được:** hệ thống cần ghi log, đo metric và hỗ trợ truy vết kết quả.
- **Dễ triển khai:** ưu tiên kiến trúc container hóa để có thể lặp lại thực nghiệm.

3.3. Kiến trúc tổng thể


Kiến trúc đề xuất gồm bốn lớp: lớp nguồn dữ liệu, lớp edge, lớp cloud và lớp ứng dụng. Lớp nguồn dữ liệu bao gồm camera/video stream, kho ảnh lớn và thiết bị di động/IoT. Lớp edge thực hiện thu thập, tiền xử lý, suy luận nhanh và quyết định offloading. Lớp cloud thực hiện suy luận nâng cao, huấn luyện/cập nhật mô hình, lưu trữ ảnh/metadata và tạo embedding. Lớp ứng dụng cung cấp dashboard, API phân tích, tìm kiếm ngữ nghĩa, cảnh báo và báo cáo.



Hình 3.1: Kiến trúc edge–cloud đề xuất cho phân tích ngữ nghĩa dữ liệu hình ảnh lớn

3.4. Luồng xử lý dữ liệu

Luồng xử lý của hệ thống gồm sáu bước chính. Thứ nhất, edge nhận dữ liệu ảnh/video từ nguồn. Thứ hai, edge thực hiện tiền xử lý như trích xuất khung hình, resize, chuẩn hóa, lọc nhiễu và nén. Thứ ba, mô hình nhẹ tại edge chạy suy luận ban đầu để phát hiện đối tượng và tính confidence. Thứ tư, bộ quyết định offloading đánh giá kết quả. Thứ năm, nếu cần, dữ liệu được gửi lên cloud để xử lý bằng mô hình mạnh hơn. Thứ sáu, kết quả cuối cùng được lưu dưới dạng metadata, embedding và được hiển thị trên dashboard.



Hình 3.2: Quy trình xử lý và quyết định offloading

3.5. Mô hình dữ liệu ngữ nghĩa

Kết quả phân tích không chỉ là ảnh đã được nhận dạng, mà là một cấu trúc metadata có thể lưu trữ, tìm kiếm và phân tích. Mỗi ảnh hoặc khung hình có thể được mô tả bởi các trường sau:

- **frame_id**: mã định danh ảnh hoặc khung hình.
- **source_id**: mã nguồn dữ liệu, ví dụ camera hoặc dataset.
- **timestamp**: thời điểm thu thập.
- **objects**: danh sách đối tượng phát hiện được, gồm nhãn, bounding box và confidence.
- **scene_tags**: nhãn bối cảnh như đường phố, phòng họp, bãi xe hoặc khu vực đông người.
- **embedding**: vector đặc trưng phục vụ tìm kiếm tương đồng.
- **processing_place**: nơi xử lý chính, gồm edge, cloud hoặc hybrid.

- **latency**: thời gian xử lý từ lúc nhận dữ liệu đến khi có kết quả.

Mô hình dữ liệu này giúp hệ thống không chỉ phát hiện đối tượng, mà còn hỗ trợ truy vấn như: tìm tất cả khung hình có xe máy, tìm ảnh có người xuất hiện trong khu vực cổng, tìm ảnh tương đồng với ảnh mẫu hoặc thống kê tần suất đối tượng theo thời gian.

3.6. Cơ chế offloading đề xuất

Bộ quyết định offloading là thành phần quan trọng nhất của mô hình edge–cloud. Quyết định offloading có thể dựa trên bốn nhóm thông tin: kết quả suy luận tại edge, tài nguyên của edge, trạng thái mạng và chính sách ứng dụng. Trong phạm vi prototype, báo cáo sử dụng quy tắc quyết định đơn giản nhưng dễ triển khai, dựa trên ba tham số chính: confidence lớn nhất, confidence trung bình và số lượng đối tượng phát hiện được. Khi mở rộng thực nghiệm, có thể bổ sung thêm mức sử dụng CPU/RAM/GPU tại edge và trạng thái mạng giữa edge với cloud.

$$D(x) = \begin{cases} \text{Edge,} & \text{nếu } c_{\max}(x) \geq \tau_{\max}, c_{\text{avg}}(x) \geq \tau_{\text{avg}}, \\ & N_{\text{obj}}(x) \leq \tau_n \text{ và } U_{\text{edge}} \leq \tau_u \\ \text{Cloud,} & \text{nếu } c_{\max}(x) < \tau_{\max} \text{ hoặc } c_{\text{avg}}(x) < \tau_{\text{avg}}, \\ & \text{hoặc } N_{\text{obj}}(x) > \tau_n \text{ hoặc } U_{\text{edge}} > \tau_u \end{cases}$$

Trong đó, $c_{\max}(x)$ là confidence lớn nhất trong các đối tượng phát hiện được; $c_{\text{avg}}(x)$ là confidence trung bình; $N_{\text{obj}}(x)$ là số lượng đối tượng; U_{edge} là mức sử dụng tài nguyên tại edge; $\tau_{\max}$, τ_{avg} , τ_n và τ_u lần lượt là ngưỡng confidence lớn nhất, ngưỡng confidence trung bình, ngưỡng số lượng đối tượng và ngưỡng tải tài nguyên edge. Trong prototype hiện tại, điều kiện tài nguyên U_{edge} được xem là tham số mở rộng, còn quyết định demo chủ yếu dựa trên $c_{\max}$, c_{avg} và N_{obj} .

Tham số	Ký hiệu	Giá trị demo	Ý nghĩa
Max confidence threshold	$\tau_{\max}$	0.60	Ngưỡng confidence lớn nhất dùng để xem xét chấp nhận kết quả xử lý tại edge.
Average confidence threshold	τ_{avg}	0.40	Ngưỡng confidence trung bình của các đối tượng được phát hiện trong ảnh hoặc khung hình.
Max object count	τ_n	10	Số lượng đối tượng tối đa cho phép xử lý tại edge trong chế độ cân bằng.
Edge resource threshold	τ_u	Tùy cấu hình	Ngưỡng tải tài nguyên tại edge, dùng khi hệ thống có đo CPU, RAM hoặc GPU.

Bảng 3.1: Các tham số quyết định offloading trong hệ thống demo

Với cấu hình demo, hệ thống giữ kết quả tại edge khi đồng thời thỏa ba điều kiện: $c_{\max} \geq 0.60$, $c_{\text{avg}} \geq 0.40$ và $N_{\text{obj}} \leq 10$. Nếu một trong các điều kiện không thỏa mãn, ví dụ confidence trung bình thấp hoặc cảnh có quá nhiều đối tượng, dữ liệu sẽ được offload lên cloud để xử lý bằng mô hình mạnh hơn. Cách thiết kế này giúp tránh trường hợp chỉ dựa vào một confidence lớn nhất nhưng bỏ qua các đối tượng có độ tin cậy thấp trong cùng ảnh.

Điều kiện	Quyết định	Lý do
Confidence đạt ngưỡng và số lượng đối tượng không vượt ngưỡng	Xử lý tại edge	Kết quả đủ tin cậy, cảnh không quá phức tạp, giúp giảm độ trễ và tiết kiệm băng thông.
Max confidence hoặc average confidence thấp	Gửi cloud	Ảnh khó hoặc có nhiều đối tượng chưa chắc chắn, cần mô hình mạnh hơn để phân tích lại.
Số lượng đối tượng vượt ngưỡng	Gửi cloud	Cảnh phức tạp, mô hình nhẹ tại edge có nguy cơ bỏ sót hoặc nhận dạng sai.
Edge quá tải tài nguyên	Gửi cloud hoặc đưa vào hàng đợi	Tránh làm edge node bị nghẽn và duy trì khả năng phản hồi của hệ thống.
Mạng cloud yếu, sự kiện không nghiêm trọng	Xử lý tạm tại edge	Duy trì hoạt động khi kết nối không ổn định.
Sự kiện quan trọng hoặc cảnh báo an toàn	Gửi cloud ưu tiên	Cần xác minh bằng mô hình chính xác hơn và lưu vết tập trung.
Dữ liệu nhạy cảm	Xử lý hoặc ẩn danh tại edge trước	Giảm rủi ro riêng tư trước khi truyền dữ liệu lên cloud.

Bảng 3.2: Quy tắc quyết định offloading trong mô hình edge–cloud

3.7. Thuật toán xử lý đề xuất

Thuật toán tổng quát có thể mô tả như sau:

1. Nhận ảnh hoặc khung hình video x tại edge.
2. Tiền xử lý x để tạo ảnh chuẩn hóa x' .
3. Chạy mô hình nhẹ M_e tại edge để thu được nhãn, bounding box và confidence.
4. Tính các đại lượng $c_{\max}$, c_{avg} , N_{obj} , U_{edge} và trạng thái mạng.
5. Nếu $c_{\max} \geq \tau_{\max}$, $c_{\text{avg}} \geq \tau_{\text{avg}}$, $N_{\text{obj}} \leq \tau_n$ và $U_{\text{edge}} \leq \tau_u$, hệ thống lưu metadata và trả kết quả tại edge.
6. Ngược lại, hệ thống gửi ảnh nén, vùng quan tâm hoặc metadata lên cloud để xử lý bằng mô hình mạnh hơn.
7. Cloud chạy mô hình mạnh M_c , tạo kết quả cuối cùng và embedding.
8. Lưu kết quả vào kho metadata, cập nhật dashboard và API tìm kiếm.

3.8. Kết luận chương 3

Chương 3 đã đề xuất mô hình nghiên cứu và kiến trúc hệ thống edge–cloud cho phân tích ngữ nghĩa dữ liệu hình ảnh lớn. Điểm chính của kiến trúc là sử dụng edge như lớp xử lý và lọc thông minh, cloud như lớp phân tích sâu và quản lý tập trung. Cơ chế offloading dựa trên max confidence, average confidence, số lượng đối tượng và tải tài nguyên giúp mô hình có khả năng cân bằng giữa độ trễ, băng thông và độ chính xác.

CHƯƠNG 4: THIẾT KẾ THỰC NGHIỆM VÀ PHƯƠNG PHÁP ĐÁNH GIÁ

4.1. Mục tiêu thực nghiệm

Thực nghiệm được thiết kế nhằm kiểm chứng các giả thuyết nghiên cứu đã nêu ở chương 1. Mục tiêu không phải chứng minh một mô hình AI mới tốt hơn mọi mô hình hiện có, mà là đánh giá hiệu quả của kiến trúc edge–cloud khi so sánh với cloud-only và edge-only. Cụ thể, thực nghiệm cần trả lời các câu hỏi:

- Edge–cloud giảm được bao nhiêu phần trăm dữ liệu gửi lên cloud?
- Độ trễ trung bình của edge–cloud thấp hơn cloud-only hay không?
- Độ chính xác của edge–cloud có gần cloud-only và cao hơn edge-only không?
- Khi thay đổi ngưỡng confidence, tỷ lệ offload và kết quả đánh giá thay đổi như thế nào?

4.2. Môi trường thực nghiệm đề xuất


Môi trường thực nghiệm có thể triển khai theo hai mức: mức tối thiểu và mức mở rộng. Mức tối thiểu dùng một máy tính cá nhân chạy Docker, trong đó edge và cloud là hai container được giới hạn tài nguyên khác nhau. Mức mở rộng dùng một thiết bị edge thật như Raspberry Pi hoặc Jetson Nano và một server cloud/GPU riêng.

Thành phần	Cấu hình tối thiểu	Cấu hình mở rộng
Edge node	Docker container giới hạn 2 CPU, 2–4 GB RAM	Raspberry Pi 4, Jetson Nano hoặc mini PC
Cloud node	Docker container 4–8 CPU, 8–16 GB RAM	Server GPU hoặc máy trạm có CUDA
Mô hình edge	YOLO-small/nano hoặc MobileNet	YOLOv8n, YOLOv8s, TensorRT/ONNX
Mô hình cloud	YOLO-medium/large hoặc mô hình chính xác hơn	YOLOv8m/l, Faster R-CNN, CLIP embedding
Dữ liệu	Tập ảnh COCO subset hoặc video mẫu	Camera/video thực tế, dataset lớn hơn
Công cụ đo	Python time, psutil, log API	Prometheus, Grafana, message queue

Bảng 4.1: Môi trường thực nghiệm đề xuất

4.3. Thiết lập tham số cho prototype

Prototype được thiết kế dưới dạng dashboard đơn giản để người dùng có thể thay đổi các ngưỡng offloading và quan sát quyết định của hệ thống. Ba tham số chính gồm max confidence threshold, average confidence threshold và max object count. Việc đưa các tham số này vào giao diện giúp liên kết trực tiếp giữa công thức nghiên cứu ở Chương 3 và quá trình chạy thử nghiệm trong hệ thống demo.



Hình 4.1: Giao diện thiết lập tham số offloading trong hệ thống prototype

Trong quá trình chạy demo, mỗi ảnh đầu vào cần ghi nhận các trường: max confidence, average confidence, số lượng đối tượng, độ trễ xử lý, dung lượng upload và quyết định cuối cùng. Các trường này là cơ sở để so sánh ba kịch bản edge-only, cloud-only và edge-cloud.

4.4. Dữ liệu thực nghiệm

Dữ liệu thực nghiệm có thể sử dụng ba nguồn. Nguồn thứ nhất là tập ảnh chuẩn COCO, phù hợp để đánh giá phát hiện đối tượng vì có nhãn và bounding box [5]. Nguồn thứ hai là video mẫu được trích xuất thành khung hình theo chu kỳ. Nguồn thứ ba là tập ảnh tự thu thập từ môi trường ứng dụng, ví dụ ảnh giao thông, ảnh khuôn viên, ảnh kho bãi hoặc ảnh camera văn phòng. Với phạm vi báo cáo học phần, có thể chọn subset từ 1.000 đến 5.000 ảnh để giảm thời gian xử lý nhưng vẫn đủ để so sánh.

Dữ liệu nên được chia thành các nhóm theo độ phức tạp:

- **Nhóm đơn giản:** ít đối tượng, đối tượng rõ, ánh sáng tốt.

- **Nhóm trung bình:** nhiều đối tượng, bối cảnh phức tạp vừa phải.
- **Nhóm khó:** đối tượng nhỏ, bị che khuất, ánh sáng yếu hoặc nhiều chuyển động.

Cách chia này giúp kiểm tra xem cơ chế offloading có thực sự gửi các trường hợp khó lên cloud hay không.

4.5. Các mô hình đối chứng

Thực nghiệm so sánh ba mô hình:

1. **Cloud-only:** edge chỉ thu thập và gửi toàn bộ ảnh/video lên cloud; cloud chạy mô hình mạnh và trả kết quả.
2. **Edge-only:** edge xử lý toàn bộ bằng mô hình nhẹ; cloud không tham gia suy luận.
3. **Edge–cloud:** edge xử lý trước; chỉ ảnh hoặc khung hình có confidence thấp, cảnh phức tạp hoặc sự kiện quan trọng mới gửi cloud.

Mô hình cloud-only được dùng làm mốc về độ chính xác, mô hình edge-only được dùng làm mốc về độ trễ và băng thông, còn mô hình edge–cloud được kỳ vọng đạt cân bằng giữa hai mô hình này.

4.6. Kịch bản thực nghiệm

4.6.1. Kịch bản 1: So sánh độ trễ

Mỗi ảnh được đưa qua ba mô hình triển khai. Hệ thống ghi lại thời gian thu thập, tiền xử lý, suy luận edge, upload, suy luận cloud, download và hậu xử lý. Tổng độ

trễ được tính như sau:

$$T_{\text{total}} = T_{\text{capture}} + T_{\text{preprocess}} + T_{\text{edge}}^{\text{infer}} + T_{\text{upload}} \\ + T_{\text{cloud}}^{\text{infer}} + T_{\text{download}} + T_{\text{postprocess}}$$

Với edge-only, các thành phần upload, cloud inference và download gần như bằng 0. Với cloud-only, edge inference có thể không tồn tại nhưng upload tăng mạnh. Với edge-cloud, tổng độ trễ phụ thuộc vào tỷ lệ ảnh được offload.

4.6.2. *Kịch bản 2: So sánh băng thông*

Băng thông được đo bằng tổng dung lượng dữ liệu gửi từ edge lên cloud. Tỷ lệ tiết kiệm băng thông được tính:

$$\eta_{\text{bw}} = 1 - \frac{S_{\text{uploaded}}}{S_{\text{raw}}}$$

Trong đó, S_{raw} là dung lượng dữ liệu thô nếu gửi toàn bộ lên cloud, còn S_{uploaded} là dung lượng thực tế được gửi trong mô hình edge-cloud.

4.6.3. *Kịch bản 3: So sánh độ chính xác*

Độ chính xác được đánh giá bằng Precision, Recall, F1-score và mAP. Nếu sử dụng COCO subset, có thể đánh giá dựa trên nhãn chuẩn. Nếu sử dụng dữ liệu tự thu thập chưa có nhãn, có thể chọn một tập nhỏ để gán nhãn thủ công hoặc dùng cloud-only làm baseline tham chiếu.

4.6.4. *Kịch bản 4: Thay đổi ngưỡng confidence*

Các ngưỡng confidence có thể được thay đổi theo nhiều mức khác nhau. Với τ_{max} , có thể thử các mức 0.3, 0.5, 0.7 và 0.9; với τ_{avg} , có thể thử các mức 0.3, 0.4, 0.5 và 0.6. Khi ngưỡng thấp, edge chấp nhận nhiều kết quả hơn, băng thông giảm nhưng có thể giảm độ chính xác. Khi ngưỡng cao, nhiều ảnh được gửi cloud hơn, độ chính

xác tăng nhưng độ trễ và băng thông cũng tăng. Kịch bản này giúp tìm điểm cân bằng phù hợp giữa độ tin cậy, độ phức tạp cảnh và chi phí truyền tải.

4.6.5. Kịch bản 5: Giả lập mạng yếu

Độ trễ mạng và băng thông giữa edge và cloud được thay đổi để mô phỏng điều kiện mạng khác nhau. Mục tiêu là kiểm tra khả năng duy trì hoạt động của edge khi cloud không ổn định. Trong trường hợp mạng yếu, hệ thống có thể ưu tiên xử lý tại edge, lưu hàng đợi cục bộ và đồng bộ lại sau.

4.7. Bộ chỉ số đánh giá

Nhóm chỉ số	Cách đo	Ý nghĩa
Latency	Thời gian từ lúc hệ thống nhận ảnh hoặc khung hình đến khi có kết quả phân tích	Đánh giá khả năng đáp ứng thời gian thực của hệ thống
Upload bandwidth	Tổng dung lượng dữ liệu được gửi từ edge lên cloud trong quá trình xử lý	Đánh giá khả năng giảm tải mạng truyền dẫn
Throughput	Số ảnh hoặc số khung hình được xử lý trong một giây	Đánh giá khả năng xử lý liên tục của hệ thống
CPU/RAM/GPU	Mức sử dụng tài nguyên tính toán tại edge node và cloud node	Đánh giá khả năng triển khai trong điều kiện thực tế
Offload ratio	Tỷ lệ ảnh hoặc khung hình được gửi lên cloud trên tổng dữ liệu đầu vào	Đánh giá hành vi của bộ quyết định offloading
Upload saving ratio	Tỷ lệ dữ liệu truyền tải được tiết kiệm so với phương án cloud-only	Đánh giá trực tiếp lợi ích giảm băng thông của mô hình edge-cloud

Bảng 4.2: Nhóm chỉ số đánh giá hiệu năng hệ thống

4.8. Thiết kế dashboard và log thực nghiệm


Để thực nghiệm có tính quan sát và dễ đánh giá, hệ thống cần ghi log theo từng ảnh hoặc từng khung hình. Mỗi bản ghi gồm: thời gian nhận, thời gian tiền xử lý, kết quả edge, quyết định offloading, thời gian upload, kết quả cloud, độ trễ tổng, dung lượng truyền, tài nguyên edge và trạng thái mạng. Dashboard có thể hiển thị các

Nhóm chỉ số	Cách đo	Ý nghĩa
Precision	Tỷ lệ kết quả dự đoán đúng trên tổng số kết quả được mô hình dự đoán	Đánh giá mức độ chính xác của kết quả nhận dạng
Recall	Tỷ lệ đối tượng thực tế được mô hình phát hiện đúng	Đánh giá khả năng phát hiện đầy đủ các đối tượng cần quan tâm
F1-score	Trung bình điều hòa giữa Precision và Recall	Đánh giá cân bằng giữa độ chính xác và khả năng phát hiện
mAP	Giá trị mean Average Precision tính theo từng lớp đối tượng	Đánh giá hiệu quả tổng thể của tác vụ phát hiện đối tượng
IoU/mIoU (<i>mở rộng</i>)	Độ chồng lấn giữa vùng dự đoán và vùng nhãn thật, dùng khi mở rộng sang semantic segmentation	Giúp liên hệ với các bài toán phân đoạn ngữ nghĩa ảnh lớn như PMNet, nhưng không phải trọng tâm của prototype hiện tại
Cost proxy	Thời gian xử lý trên cloud, dung lượng truyền tải và dung lượng lưu trữ phát sinh	Ước lượng chi phí vận hành của hệ thống

Bảng 4.3: Nhóm chỉ số đánh giá chất lượng phân tích và chi phí

biểu đồ như latency theo thời gian, tỷ lệ offload, băng thông tiết kiệm, số lượng đối tượng theo lớp và phân bố confidence.

4.9. Quy trình thực nghiệm tổng quát



Hình 4.2: Quy trình thực nghiệm đề xuất

4.10. Kết luận chương 4

Chương 4 đã trình bày thiết kế thực nghiệm chi tiết, bao gồm môi trường triển khai, tham số prototype, dữ liệu, mô hình đối chứng, kịch bản đo lường và bộ chỉ số đánh giá. Với thiết kế này, đề tài có cơ sở để tạo ra kết quả định lượng khi triển khai đầy đủ, đồng thời có thể sử dụng prototype để minh họa cơ chế offloading trong phạm vi học phần. Phân tích định tính và kết quả minh họa sẽ được trình bày ở chương 5.

CHƯƠNG 5: KHUNG ĐÁNH GIÁ, KẾT QUẢ PROTOTYPE VÀ PHÂN TÍCH KHẢ NĂNG ỨNG DỤNG MÔ HÌNH

5.1. Mục tiêu đánh giá

Chương này trình bày khung đánh giá và kết quả thử nghiệm sơ bộ từ hệ thống prototype edge–cloud computing cho truyền thông đa phương tiện và phân tích ngữ nghĩa dữ liệu hình ảnh lớn. Mục tiêu của chương không phải là khẳng định hiệu năng cuối cùng của mô hình trên quy mô lớn, mà nhằm minh họa cách hệ thống hoạt động, cách bộ quyết định offloading lựa chọn xử lý tại edge hoặc cloud, đồng thời so sánh bước đầu giữa ba kịch bản: cloud-only, edge-only và edge–cloud. Trong phạm vi bài tiểu luận, hệ thống prototype được sử dụng để kiểm tra các chỉ số cơ bản như độ trễ xử lý, dung lượng upload, throughput, confidence, số lượng đối tượng phát hiện được, mức sử dụng CPU/RAM và tỷ lệ offload. Các kết quả này có giá trị minh họa cho tính khả thi của kiến trúc đề xuất, nhưng vẫn cần được kiểm chứng thêm trên tập dữ liệu lớn hơn, nhiều loại ảnh/video hơn và môi trường triển khai thực tế với nhiều edge node.

5.2. Nguyên tắc quyết định offloading trong prototype

Trong hệ thống prototype, quyết định xử lý tại edge hay gửi lên cloud được xác định dựa trên ba tham số chính: độ tin cậy lớn nhất của kết quả nhận dạng, độ tin cậy trung bình của các đối tượng phát hiện được và số lượng đối tượng trong ảnh. Cụ thể, một ảnh hoặc khung hình được giữ lại xử lý tại edge khi đồng thời thỏa mãn các điều kiện:

$$c_{max}(x) \geq \tau_{max}, \quad c_{avg}(x) \geq \tau_{avg}, \quad N_{obj}(x) \leq \tau_n$$

Trong đó, $c_{max}(x)$ là confidence lớn nhất, $c_{avg}(x)$ là confidence trung bình, $N_{obj}(x)$ là số lượng đối tượng được phát hiện trong ảnh hoặc khung hình x . Trong prototype, các ngưỡng được thiết lập như sau: $\tau_{max} = 0.60$, $\tau_{avg} = 0.40$ và $\tau_n = 10$.

Nếu một trong các điều kiện trên không thỏa mãn, hệ thống sẽ offload dữ liệu lên cloud để xử lý bằng mô hình mạnh hơn. Cơ chế này giúp hệ thống tránh việc giữ lại tại edge các ảnh có confidence thấp hoặc cảnh có quá nhiều đối tượng, vì đây thường là các trường hợp phức tạp và dễ làm giảm độ chính xác nếu chỉ xử lý bằng mô hình nhẹ.

Tham số	Ký hiệu	Giá trị	Ý nghĩa
Max confidence threshold	τ_{max}	0.60	Ngưỡng confidence lớn nhất để chấp nhận kết quả tại edge
Average confidence threshold	τ_{avg}	0.40	Ngưỡng confidence trung bình của các đối tượng phát hiện được
Max object count	τ_n	10	Số lượng đối tượng tối đa cho phép xử lý tại edge

Bảng 5.1: Các tham số quyết định offloading trong hệ thống prototype

5.3. Kết quả thử nghiệm sơ bộ trên prototype

Để đánh giá bước đầu mô hình đề xuất, prototype được chạy với ba kịch bản xử lý. Kịch bản cloud-only gửi toàn bộ dữ liệu lên cloud để xử lý. Kịch bản edge-only xử lý toàn bộ dữ liệu tại edge và không upload dữ liệu lên cloud. Kịch bản edge-cloud sử dụng bộ quyết định offloading để lựa chọn xử lý tại edge hoặc gửi lên cloud tùy theo confidence và độ phức tạp của ảnh.

Bảng 5.2 trình bày kết quả so sánh ba kịch bản xử lý trên hệ thống prototype. Các số liệu này là kết quả thử nghiệm sơ bộ trên prototype, chưa đại diện cho hiệu năng

cuối cùng của hệ thống khi triển khai trên tập dữ liệu lớn hoặc môi trường nhiều camera thực tế.

Chỉ số đánh giá	Cloud-Only	Edge-Only	Edge-Cloud
Avg Latency (ms)	134.62	52.46	127.31
P95 Latency (ms)	167.70	41.08	144.53
Total Upload (bytes)	1,396,999	0	1,168,715
Throughput (img/s)	7.4283	19.0630	7.8546
Avg Confidence	0.23	0.20	0.21
Avg Object Count	0.67	0.60	0.60
Avg CPU Usage (%)	3.23	3.75	2.69
Avg RAM Usage (MB)	76.24	402.18	394.89
Offload Ratio (%)	100%	0%	80.0%
Bandwidth Savings vs Cloud-Only	0%	100%	16.3%

Bảng 5.2: Kết quả so sánh ba kịch bản xử lý trên hệ thống prototype

Giá trị P95 latency của edge-only nhỏ hơn latency trung bình do một số mẫu có độ trễ cao bất thường làm tăng giá trị trung bình; khi triển khai thực nghiệm đầy đủ cần phân tích thêm phân bố latency và loại bỏ outlier nếu cần.

5.4. Phân tích kết quả prototype

5.4.1. Độ trễ xử lý

Kết quả cho thấy mô hình edge-only có độ trễ trung bình thấp nhất, đạt 52.46 ms. Điều này phù hợp với đặc điểm của xử lý tại edge, do dữ liệu không cần truyền lên cloud trong quá trình suy luận. Tuy nhiên, edge-only phụ thuộc hoàn toàn vào tài nguyên tại edge và thường chỉ phù hợp với các tác vụ có độ phức tạp vừa phải hoặc sử dụng mô hình nhẹ.

Mô hình cloud-only có độ trễ trung bình 134.62 ms. Độ trễ này bao gồm thời gian

upload dữ liệu lên cloud, thời gian suy luận tại cloud và thời gian trả kết quả. Mặc dù cloud có tài nguyên tính toán mạnh hơn, việc truyền dữ liệu qua mạng vẫn làm tăng tổng thời gian xử lý.

Mô hình edge-cloud đạt độ trễ trung bình 127.31 ms, thấp hơn cloud-only nhưng cao hơn edge-only. Kết quả này cho thấy edge-cloud có khả năng giảm một phần độ trễ so với xử lý tập trung hoàn toàn, nhưng hiệu quả phụ thuộc lớn vào tỷ lệ dữ liệu được offload lên cloud. Trong thử nghiệm này, tỷ lệ offload còn cao nên độ trễ của edge-cloud vẫn gần với cloud-only.

5.4.2. *Băng thông truyền tải*

Về dung lượng upload, cloud-only phải gửi toàn bộ dữ liệu lên cloud, với tổng dung lượng 1,396,999 bytes. Edge-only không phát sinh dữ liệu upload, do toàn bộ quá trình xử lý được thực hiện tại edge. Đây là ưu điểm rõ ràng của edge-only về tiết kiệm băng thông.

Đối với edge-cloud, tổng dung lượng upload là 1,168,715 bytes, thấp hơn cloud-only. Mức tiết kiệm băng thông đạt 16.3% so với cloud-only. Kết quả này cho thấy bộ quyết định offloading đã giữ lại một phần dữ liệu tại edge, từ đó giảm lượng dữ liệu cần truyền lên cloud. Tuy nhiên, do tỷ lệ offload của edge-cloud là 80.0%, phần lớn dữ liệu vẫn được gửi lên cloud, làm cho mức tiết kiệm băng thông chưa cao.

5.4.3. *Throughput*

Throughput của edge-only đạt 19.0630 ảnh/giây, cao hơn đáng kể so với cloud-only và edge-cloud. Nguyên nhân là kịch bản edge-only không phải thực hiện upload dữ liệu và không chờ kết quả từ cloud. Cloud-only đạt 7.4283 ảnh/giây, trong khi edge-cloud đạt 7.8546 ảnh/giây.

Kết quả này cho thấy edge-cloud có throughput cao hơn nhẹ so với cloud-only,

nhưng chưa tạo ra khác biệt lớn do tỷ lệ offload còn cao. Nếu điều chỉnh ngưỡng offloading hợp lý hơn hoặc sử dụng dữ liệu có nhiều ảnh đơn giản hơn, edge–cloud có thể giữ lại nhiều ảnh tại edge hơn, từ đó cải thiện throughput và giảm tải cho cloud.

5.4.4. Confidence và số lượng đối tượng

Cloud-only đạt confidence trung bình cao nhất với giá trị 0.23. Edge-only đạt confidence trung bình 0.20, thấp hơn cloud-only do sử dụng mô hình nhẹ hơn hoặc môi trường xử lý hạn chế hơn. Edge–cloud đạt confidence trung bình 0.21, nằm giữa hai mô hình còn lại.

Sự khác biệt confidence trong thử nghiệm sơ bộ chưa lớn, nhưng phản ánh xu hướng hợp lý: cloud có khả năng xử lý bằng mô hình mạnh hơn, còn edge ưu tiên tốc độ và tiết kiệm tài nguyên. Với các ảnh có nhiều đối tượng hoặc confidence thấp, edge–cloud có thể gửi dữ liệu lên cloud để cải thiện độ tin cậy của kết quả phân tích.

5.4.5. Tài nguyên tính toán

Mức sử dụng CPU trung bình của edge–cloud là 2.69%, thấp hơn cloud-only và edge-only trong thử nghiệm này. Tuy nhiên, mức sử dụng RAM của edge–cloud đạt 394.89 MB, gần với edge-only là 402.18 MB và cao hơn cloud-only là 76.24 MB. Điều này cho thấy khi triển khai prototype, thành phần edge và cơ chế điều phối có thể tiêu tốn bộ nhớ đáng kể, đặc biệt nếu hệ thống duy trì mô hình AI, cache ảnh, metadata hoặc hàng đợi xử lý.

Kết quả này cho thấy khi triển khai thực tế, cần tối ưu bộ nhớ tại edge, chẳng hạn giảm kích thước mô hình, giới hạn batch size, giải phóng ảnh tạm sau khi xử lý và tách riêng các thành phần logging/dashboard khỏi luồng suy luận chính.

5.4.6. Tỷ lệ offload

Tỷ lệ offload của edge–cloud là 80.0%, nghĩa là phần lớn ảnh trong thử nghiệm chưa thỏa điều kiện giữ lại tại edge. Điều này có thể xuất phát từ ngưỡng confidence tương đối cao, dữ liệu đầu vào có nhiều ảnh phức tạp, hoặc điều kiện số lượng đối tượng tối đa đang giới hạn ở mức 10.

Kết quả này có ý nghĩa quan trọng đối với mô hình đề xuất. Nếu ngưỡng offloading quá chặt, edge–cloud sẽ hoạt động gần giống cloud-only, làm giảm lợi ích tiết kiệm băng thông. Ngược lại, nếu ngưỡng quá lỏng, hệ thống có thể giữ lại quá nhiều dữ liệu tại edge, làm giảm độ chính xác. Vì vậy, việc lựa chọn ngưỡng τ_{max} , τ_{avg} và τ_n cần được xem là một tham số thực nghiệm quan trọng trong các nghiên cứu tiếp theo.

5.5. Khung so sánh định tính giữa các mô hình triển khai

Bên cạnh kết quả prototype, đề tài tiếp tục sử dụng khung so sánh định tính để làm rõ ưu điểm và hạn chế của từng mô hình triển khai. Ba mô hình được so sánh gồm cloud-only, edge-only và edge–cloud.

5.6. Nhận xét về khả năng ứng dụng từ kết quả prototype

Mô hình edge–cloud có thể ứng dụng trong nhiều hệ thống truyền thông đa phương tiện. Trong giám sát video thông minh, edge có thể phát hiện nhanh người, phương tiện hoặc sự kiện bất thường, trong khi cloud tổng hợp dữ liệu từ nhiều camera và thực hiện phân tích chuyên sâu. Trong giao thông thông minh, edge có thể xử lý tại nút giao để giảm độ trễ cảnh báo, còn cloud phân tích xu hướng lưu lượng theo khu vực và thời gian.

Trong kho ảnh số và truyền thông số, edge có thể tiền xử lý, gắn nhãn ban đầu và loại bỏ dữ liệu trùng lặp, còn cloud tạo embedding phục vụ tìm kiếm ngữ nghĩa. Trong công nghiệp và kho bãi, edge có thể phát hiện nhanh đối tượng, người lao

Tiêu chí	Cloud-only	Edge-only	Edge-cloud
Độ trễ xử lý	Phụ thuộc truyền dữ liệu lên cloud và xử lý tập trung	Thấp nếu mô hình nhẹ và edge đủ tài nguyên	Cân bằng hơn: ảnh đơn giản xử lý tại edge, ảnh khó gửi cloud
Băng thông truyền tải	Cao do gửi dữ liệu thô lên cloud	Rất thấp hoặc bằng 0 khi suy luận	Thấp hơn cloud-only nếu offloading hiệu quả
Độ chính xác	Có thể cao nhờ mô hình mạnh	Có thể thấp hơn do dùng mô hình nhẹ	Có thể tiệm cận cloud-only nếu ảnh khó được gửi lên cloud
Tài nguyên edge	Yêu cầu thấp	Yêu cầu cao hơn	Trung bình, phụ thuộc mức xử lý tại edge
Tài nguyên cloud	Yêu cầu cao	Yêu cầu thấp	Phụ thuộc tỷ lệ dữ liệu được offload
Khả năng mở rộng	Phụ thuộc năng lực cloud và đường truyền	Phụ thuộc số lượng và năng lực edge node	Có thể mở rộng theo mô hình nhiều edge node
Phù hợp ứng dụng	Phân tích batch, lưu trữ tập trung	Ứng dụng đơn giản, cần phản hồi nhanh	Ứng dụng cần cân bằng độ trễ, băng thông và độ chính xác

Bảng 5.3: Khung so sánh định tính giữa các mô hình triển khai

động hoặc tình huống bất thường, trong khi cloud lưu trữ lịch sử và hỗ trợ báo cáo tổng hợp.

Các ứng dụng trên cho thấy mô hình edge-cloud phù hợp với các bài toán có dữ liệu lớn, phân tán, yêu cầu xử lý gần thời gian thực nhưng vẫn cần năng lực phân tích tập trung của cloud.

5.7. Hạn chế của nghiên cứu

Mặc dù prototype đã cung cấp kết quả minh họa ban đầu, nghiên cứu vẫn còn một số hạn chế. Thứ nhất, hệ thống chưa được kiểm thử trên môi trường thực tế với nhiều edge node và nhiều luồng video đồng thời. Thứ hai, dữ liệu thử nghiệm còn hạn chế, chưa đủ để đánh giá đầy đủ độ chính xác nhận dạng trong nhiều điều kiện ánh sáng, góc nhìn, mật độ đối tượng và chất lượng ảnh khác nhau.

Thứ ba, các chỉ số về độ chính xác như Precision, Recall, F1-score hoặc mAP chưa được đánh giá đầy đủ trên bộ dữ liệu có nhãn chuẩn. Do đó, các giá trị confidence trong prototype chỉ phản ánh mức tin cậy do mô hình trả về, chưa thay thế cho đánh giá độ chính xác theo ground truth. Thứ tư, hệ thống chưa đánh giá sâu các vấn đề

về bảo mật truyền dữ liệu giữa edge và cloud, quản lý phiên bản mô hình AI, tối ưu năng lượng cho thiết bị edge và khả năng chịu lỗi khi mất kết nối mạng.

5.8. Kết luận chương 5

Chương 5 đã trình bày khung đánh giá, kết quả thử nghiệm sơ bộ từ prototype và phân tích định tính giữa ba mô hình cloud-only, edge-only và edge-cloud. Kết quả prototype cho thấy edge-only có ưu điểm rõ rệt về độ trễ và băng thông, cloud-only có lợi thế về xử lý tập trung, còn edge-cloud tạo ra hướng cân bằng giữa hai mô hình này.

Trong thử nghiệm sơ bộ, edge-cloud đạt độ trễ trung bình thấp hơn cloud-only và tiết kiệm 16.3% băng thông so với cloud-only. Tuy nhiên, tỷ lệ offload 80.0% cho thấy hệ thống vẫn gửi phần lớn dữ liệu lên cloud, do đó cần tiếp tục điều chỉnh ngưỡng offloading và mở rộng thực nghiệm trên dữ liệu lớn hơn. Những kết quả này cho thấy mô hình đề xuất có tiềm năng ứng dụng trong các hệ thống truyền thông đa phương tiện cần xử lý dữ liệu hình ảnh lớn theo hướng phân tán, linh hoạt và có khả năng mở rộng.

CHƯƠNG 6: KHẢ NĂNG TRIỂN KHAI VÀ ỨNG DỤNG THỰC TẾ

6.1. Ứng dụng trong giám sát video thông minh

Trong hệ thống giám sát video, edge node có thể đặt gần camera hoặc tại gateway cục bộ. Edge xử lý phát hiện người, phương tiện, chuyển động bất thường hoặc xâm nhập vùng cấm. Chỉ khi phát hiện sự kiện quan trọng hoặc kết quả không chắc chắn, dữ liệu mới được gửi lên cloud để phân tích sâu và lưu trữ dài hạn. Cách triển khai này phù hợp với tòa nhà, khu công nghiệp, trường học, bệnh viện và hệ thống camera công cộng.

6.2. Ứng dụng trong giao thông thông minh

Trong giao thông thông minh, camera tại nút giao có thể ghi nhận mật độ phương tiện, loại phương tiện, ùn tắc, vi phạm làn đường hoặc tai nạn. Edge xử lý nhanh tại nút giao để hỗ trợ cảnh báo thời gian thực. Cloud tổng hợp dữ liệu từ nhiều nút giao để phân tích xu hướng, tối ưu đèn tín hiệu và tạo báo cáo quản lý. Đây là ứng dụng điển hình cần kết hợp độ trễ thấp tại edge và phân tích tổng hợp tại cloud.


6.3. Ứng dụng trong kho ảnh số và truyền thông số

Các cơ quan truyền thông, doanh nghiệp nội dung số hoặc hệ thống quản lý tài sản số có thể sử dụng mô hình này để tự động gắn thẻ ảnh, phân loại nội dung, phát hiện trùng lặp, tìm kiếm ảnh theo ngữ nghĩa và tạo báo cáo. Edge có thể xử lý bước đầu khi ảnh được tải lên, cloud tạo embedding và chỉ mục tìm kiếm. Người dùng có thể tìm kiếm bằng các truy vấn như “ảnh có xe cứu hỏa”, “ảnh đông người”, hoặc “ảnh tương tự mẫu này”.

6.4. Ứng dụng trong công nghiệp và kho bãi

Trong nhà máy hoặc kho bãi, camera có thể giám sát dây chuyền sản xuất, phát hiện lỗi sản phẩm, kiểm tra an toàn lao động và theo dõi hàng hóa. Edge xử lý gần camera để phản hồi nhanh, ví dụ dừng băng chuyền khi phát hiện vật thể nguy hiểm. Cloud lưu trữ kết quả, phân tích tỷ lệ lỗi và hỗ trợ cải tiến quy trình.

6.5. Kiến trúc ứng dụng mẫu



Hình 6.1: Kiến trúc ứng dụng mẫu cho hệ thống phân tích ảnh/video edge-cloud

6.6. Lộ trình triển khai sản phẩm thử nghiệm

Để đề tài có sản phẩm rõ ràng, có thể triển khai theo bốn giai đoạn:

1. **Giai đoạn 1:** xây dựng pipeline xử lý ảnh đơn lẻ, chạy edge-only và cloud-only.
2. **Giai đoạn 2:** bổ sung bộ quyết định offloading và cơ chế gửi dữ liệu từ edge lên cloud.
3. **Giai đoạn 3:** xây dựng dashboard hiển thị kết quả, latency, băng thông và tỷ lệ offload.
4. **Giai đoạn 4:** thêm tìm kiếm ngữ nghĩa bằng embedding và đánh giá trên dataset lớn hơn.

6.7. Kết luận chương 6

Chương 6 đã làm rõ khả năng ứng dụng của mô hình edge–cloud trong giám sát video, giao thông thông minh, kho ảnh số, truyền thông số và công nghiệp. Các ứng dụng này đều có điểm chung là dữ liệu ảnh/video lớn, cần xử lý nhanh tại nguồn nhưng vẫn cần cloud để phân tích sâu, quản lý tập trung và cung cấp dịch vụ tìm kiếm/nghiệp vụ.

CHƯƠNG 7: THÁCH THỨC, BẢO MẬT VÀ HƯỚNG PHÁT TRIỂN

7.1. Thách thức về cân bằng độ trễ và độ chính xác

Thách thức lớn nhất của mô hình edge–cloud là chọn đúng dữ liệu cần gửi lên cloud. Nếu gửi quá ít, hệ thống có thể bỏ sót các trường hợp khó. Nếu gửi quá nhiều, mô hình gần giống cloud-only và mất lợi thế về băng thông. Vì vậy, cần điều chỉnh ngưỡng confidence, ưu tiên theo loại sự kiện và kết hợp thêm các tín hiệu như tải edge, độ trễ mạng và mức độ quan trọng của nguồn dữ liệu.

7.2. Thách thức về quản lý mô hình

Trong hệ thống có nhiều edge node, mỗi edge có thể dùng phiên bản mô hình khác nhau. Nếu không quản lý tốt, kết quả phân tích giữa các edge có thể không đồng nhất. Cloud nên đóng vai trò quản lý vòng đời mô hình: huấn luyện/cập nhật, kiểm thử, đóng gói, phân phối xuống edge và thu thập log để đánh giá drift. Đây là vấn đề quan trọng khi mở rộng từ demo sang hệ thống thực tế.

7.3. Bảo mật và riêng tư dữ liệu

Dữ liệu hình ảnh có thể chứa thông tin cá nhân hoặc thông tin nhạy cảm. Vì vậy, mô hình đề xuất cần tích hợp bảo mật ngay từ thiết kế:

- Xác thực giữa edge node và cloud bằng API key, token hoặc chứng chỉ.
- Mã hóa dữ liệu truyền qua mạng bằng HTTPS/TLS.
- Ẩn danh hoặc làm mờ khuôn mặt/biên số tại edge trước khi gửi cloud.
- Phân quyền truy cập dashboard và API theo vai trò.

- Ghi log truy cập, log xử lý và log thay đổi mô hình.
- Quy định thời gian lưu trữ ảnh gốc, metadata và embedding.

7.4. Hướng phát triển nghiên cứu

Các hướng phát triển tiếp theo gồm:

- **Offloading thích ứng:** sử dụng học máy hoặc học tăng cường để tự động chọn nơi xử lý.
- **Nén đặc trưng trung gian:** edge gửi feature hoặc embedding thay vì ảnh gốc để giảm băng thông.
- **Federated learning:** nhiều edge cùng cải thiện mô hình mà không cần gửi dữ liệu thô về cloud.
- **Tối ưu mô hình:** lượng tử hóa, pruning, ONNX hoặc TensorRT để tăng tốc suy luận tại edge.
- **Phân tích đa phương thức:** kết hợp ảnh, video, âm thanh và văn bản để hiểu nội dung sâu hơn.
- **Tìm kiếm ngữ nghĩa nâng cao:** dùng mô hình thị giác-ngôn ngữ để tìm kiếm bằng ngôn ngữ tự nhiên.

7.5. Kết luận chương 7

Chương 7 đã phân tích các thách thức về độ trễ, độ chính xác, quản lý mô hình, bảo mật và riêng tư dữ liệu. Các hướng phát triển như offloading thích ứng, federated learning và tìm kiếm đa phương thức cho thấy đề tài có khả năng mở rộng thành nghiên cứu sâu hơn hoặc sản phẩm thử nghiệm hoàn chỉnh.

CHƯƠNG 8: KẾT LUẬN

8.1. Kết quả đạt được

Bài báo cáo đã trình bày một cách có hệ thống đề tài edge–cloud computing cho truyền thông đa phương tiện và phân tích ngữ nghĩa dữ liệu hình ảnh lớn. Nội dung đã làm rõ bối cảnh, phát biểu bài toán, mục tiêu, câu hỏi nghiên cứu, nền tảng kỹ thuật, kiến trúc đề xuất, cơ chế offloading, thiết kế thực nghiệm, prototype minh họa, chỉ số đánh giá và khả năng ứng dụng thực tế.

Điểm trọng tâm của đề tài là chuyển từ cách nhìn “xử lý ảnh bằng một mô hình AI” sang cách nhìn “thiết kế hệ thống xử lý phân tán cho dữ liệu hình ảnh lớn”. Trong hệ thống này, edge giúp giảm độ trễ và băng thông, còn cloud giúp duy trì độ chính xác và cung cấp phân tích tổng hợp. Cơ chế offloading là thành phần quyết định giúp cân bằng giữa hai phía.

8.2. Ý nghĩa nghiên cứu và ứng dụng

Về mặt nghiên cứu, đề tài hệ thống hóa các khái niệm và nghiên cứu liên quan đến edge computing, cloud computing, collaborative inference và phân tích ngữ nghĩa hình ảnh. Về mặt ứng dụng, mô hình đề xuất có thể triển khai trong giám sát video, giao thông thông minh, kho ảnh số, truyền thông số và công nghiệp. Về mặt thực nghiệm, đề tài đã xác định được quy trình đo lường và bộ chỉ số cần thiết để so sánh cloud-only, edge-only và edge–cloud; prototype hiện tại đóng vai trò minh họa cơ chế offloading và cần được mở rộng để tạo kết quả định lượng đầy đủ.

8.3. Hạn chế

Do phạm vi báo cáo, nội dung chưa triển khai đầy đủ trên một hệ thống camera thực tế quy mô lớn và chưa đánh giá trên dataset lớn. Các kết quả trong báo cáo chủ yếu là thiết kế thực nghiệm, phương án đánh giá và prototype minh họa. Vì vậy, các số

liệu demo chưa nên được xem là kết luận định lượng cuối cùng. Khi triển khai thực tế, cần tiếp tục xử lý các vấn đề như tối ưu mô hình, bảo mật dữ liệu, giám sát hệ thống, quản lý phiên bản mô hình và độ ổn định mạng.

8.4. Hướng nghiên cứu tiếp theo

Hướng nghiên cứu tiếp theo là triển khai hệ thống thử nghiệm hoàn chỉnh, chạy trên dataset thật, đo các chỉ số latency, bandwidth, mAP, throughput và resource usage; sau đó mở rộng sang offloading thích ứng, tìm kiếm ngữ nghĩa bằng CLIP, tối ưu mô hình cho edge và federated learning.

TÀI LIỆU THAM KHẢO

- [1] W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu, “Edge computing: Vision and challenges,” *IEEE Internet of Things Journal*, vol. 3, no. 5, pp. 637–646, 2016. [Online]. Available: <https://doi.org/10.1109/JIOT.2016.2579198>
- [2] F. Bonomi, R. Milito, J. Zhu, and S. Addepalli, “Fog computing and its role in the internet of things,” in *Proceedings of the First Edition of the MCC Workshop on Mobile Cloud Computing*. ACM, 2012, pp. 13–16. [Online]. Available: <https://doi.org/10.1145/2342509.2342513>
- [3] M. Armbrust, A. Fox, R. Griffith, A. D. Joseph, R. Katz, A. Konwinski, G. Lee, D. Patterson, A. Rabkin, I. Stoica, and M. Zaharia, “A view of cloud computing,” *Communications of the ACM*, vol. 53, no. 4, pp. 50–58, 2010. [Online]. Available: <https://doi.org/10.1145/1721654.1721672>
- [4] M. Satyanarayanan, “The emergence of edge computing,” *Computer*, vol. 50, no. 1, pp. 30–39, 2017. [Online]. Available: <https://doi.org/10.1109/MC.2017.9>
- [5] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, “Microsoft COCO: Common objects in context,” in *European Conference on Computer Vision*. Springer, 2014, pp. 740–755. [Online]. Available: https://doi.org/10.1007/978-3-319-10602-1_48
- [6] Y. Kang, J. Hauswald, C. Gao, A. Rovinski, T. Mudge, J. Mars, and L. Tang, “Neurosurgeon: Collaborative intelligence between the cloud and mobile edge,” in *Proceedings of the Twenty-Second International Conference on Architectural Support for Programming Languages and Operating Systems*. ACM, 2017, pp. 615–629. [Online]. Available: <https://doi.org/10.1145/3037697.3037698>
- [7] S. Teerapittayanon, B. McDanel, and H. T. Kung, “Distributed deep neural networks over the cloud, the edge and end devices,” in *2017 IEEE 37th International*

- Conference on Distributed Computing Systems*. IEEE, 2017, pp. 328–339. [Online]. Available: <https://doi.org/10.1109/ICDCS.2017.226>
- [8] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “Imagenet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems*, vol. 25, 2012. [Online]. Available: <https://proceedings.neurips.cc/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html>
- [9] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778. [Online]. Available: <https://doi.org/10.1109/CVPR.2016.90>
- [10] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 779–788. [Online]. Available: <https://doi.org/10.1109/CVPR.2016.91>
- [11] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, “Learning transferable visual models from natural language supervision,” in *Proceedings of the 38th International Conference on Machine Learning*, 2021, pp. 8748–8763. [Online]. Available: <https://proceedings.mlr.press/v139/radford21a.html>
- [12] W.-Q. Ren, Y.-B. Qu, C. Dong, Y.-Q. Jing, H. Sun, Q.-H. Wu, and S. Guo, “A survey on collaborative dnn inference for edge intelligence,” *Machine Intelligence Research*, vol. 20, no. 3, pp. 370–395, 2023. [Online]. Available: <https://doi.org/10.1007/s11633-022-1391-7>
- [13] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, and H. Adam, “MobileNets: Efficient convolutional neural networks for mobile vision applications,” *arXiv preprint arXiv:1704.04861*, 2017. [Online]. Available: <https://arxiv.org/abs/1704.04861>

- [14] Y. Wang *et al.*, “End-edge-cloud collaborative computing for deep learning: A comprehensive survey,” *IEEE Communications Surveys & Tutorials*, 2024. [Online]. Available: <https://doi.org/10.1109/COMST.2024.3393230>
- [15] Ultralytics, “YOLOv8: A state-of-the-art real-time object detection model,” Online documentation, 2023, accessed: 2026-05-16. [Online]. Available: <https://docs.ultralytics.com/models/yolov8/>